Asociación de variables

Daniel Miranda

Metodologías Cuantitativas de Investigación

Contenidos

- Asociación entre variables
- Chi cuadrado
- Correlación

Chi-cuadrado

Prueba χ^2

Evalúa la relación entre dos o más variables categóricas (nominales u ordinales).

En este ejemplo, entre género y conductas de ayuda.

	No ayuda	Ayuda poco	Ayuda mucho
Mujeres	8	23	20
Hombres	13	17	15

Prueba χ^2

- La prueba χ^2 evalúa qué tanto se alejan los datos observados en una muestra de una distribución teórica, es decir, si los datos *observados* se ajustan a lo *esperado* teóricamente.
- ¿Qué distribución debiéramos esperar en base a la hipótesis nula?
- Se puede evaluar las hipótesis acerca de proporciones poblacionales considerando **las distancias** (o diferencia o ajuste) entre las ***frecuencias observadas*** y las ***frecuencias esperadas*** o *supuestas* para cada categoría (acorde a la hipótesis nula).

¿Qué asociación habría entre estas dos variables?

	Hombre	Mujer	Total
Fuma	50	0	50
No Fuma	0	50	50
Total	50	50	100

y en esta distribución ¿qué asociación habría entre estas dos variables?

	Hombre	Mujer	Total
Fuma	25	25	50
No Fuma	25	25	50
Total	50	50	100

Formula abreviada de χ^2 en tablas de contingencia de 2 X 2 con 1 grado de libertad

	No ayuda	Ayuda	Total
Mujeres	a	b	(a + b)
Hombres	c	d	(c + d)
Total	(a + c)	(b + d)	N

$$fe_a = \frac{(a + b)\,(a+c)}{N}$$

Las frecuencias **esperadas al azar** se pueden calcular multiplicando la frecuencia total de la columna y de la fila, dividiendo por el *N* total

Formula abreviada de χ^2 en tablas de contingencia de 2 X 2 con 1 grado de libertad

$$fe_a = \frac{(a + b)\ (a+c)}{N}$$

$$fe_b = \frac{(a + b)\ (b+d)}{N}$$

$$fe_c = \frac{(c + d)\ (a+c)}{N}$$

$$fe_d = \frac{(c + d)\ (b+d)}{N}$$

	No ayuda	Ayuda	Total
Mujeres	a	b	(a + b)
Hombres	c	d	(c + d)
Total	(a + c)	(b + d)	N

$$\chi^2 = \sum \frac{\left(f_o - f_e\right)^2}{f_e}$$

¿Cuáles serían las frecuencias esperadas en base a la hipótesis nula?

	No ayuda	Ayuda poco	Ayuda mucho	Total
Mujeres	7	23	30	60
Hombres	33	37	20	90
Total	40	60	50	150

- En tablas de contingencia donde los *n* de fila y columna son distintos, calcular la frecuencia esperada es un poco más complicado…
- Las frecuencias esperadas al azar se pueden calcular multiplicando la frecuencia total de la columna y de la fila, dividiendo por el *N* total

χ^2: la fórmula

- Básicamente consiste en evaluar cuanto se alejan las frecuencias observadas de las esperadas
- Si aceptamos la hipótesis nula decimos que las frecuencias observadas se ajustan a las esperadas (esto es, no hay diferencias entre lo observado y lo esperado acorde a la hipótesis nula)
- La fórmula para el estadístico χ^2 es básicamente sumar las diferencias (al cuadrado y dividir por la frecuencia esperada)

$$\chi^2 = \sum \frac{\left(f_o - f_e\right)^2}{f_e}$$

χ^2: la fórmula

- Las diferencias corresponden a la distribución aleatoria χ^2 que se basa en la distribución normal.
- Para evaluar la significación estadística de χ^2 observado debemos comparar dicho valor con el que se obtiene de la distribución (tabla) de χ^2 , que indica la probabilidad de ocurrencia de dicho valor con ciertos grados de libertad.

$$\chi^2 = \sum \frac{\left(f_o - f_e\right)^2}{f_e}$$

Formula abreviada de χ^2 en tablas de contingencia de 2 X 2 con 1 grado de libertad

	No ayuda	Ayuda poco	Total
Mujeres	a	b	(a + b)
Hombres	c	d	(c + d)
Total	(a + c)	(b + d)	N

$$\chi^2 = \frac{N\,(ad - bc)^2}{(a+c)\,(b+d)\,(a+b)\,(c+d)}$$

Grados de libertad

No todos los valores son «libres» ya que pueden estar determinados por el resto

La fórmula para tablas de contingencia es

$$df = (j - 1)\ (i - 1)$$

Cantidad de filas menos uno por cantidad de columnas menos uno

Los totales ya están dados, porque el estadístico se basa en la diferencia entre la frecuencia esperada y la observada.

Nuestra tabla tiene dos grados de libertad

	No ayuda	Ayuda poco	Ayuda mucho	Total
Mujeres			30	60
Hombres	33			90
Total	40	60	50	150

Distribución χ^2

Puntos de corte (equivalentes a $z = 1.96$)

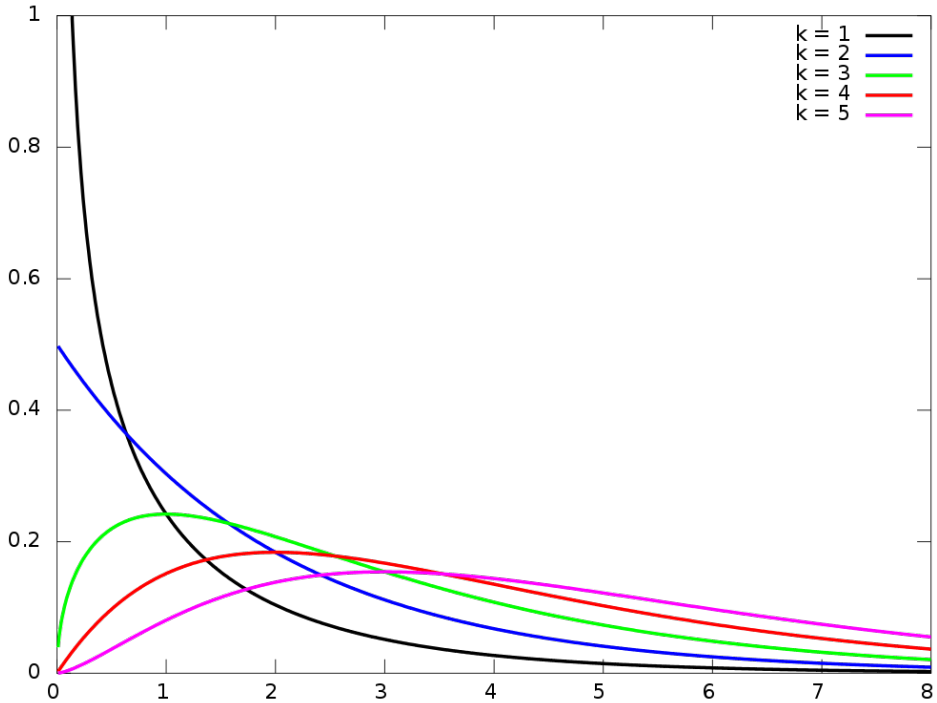

df	**χ^2 (p = .05)**
1	3.84
2	5.99
3	7.82
4	9.49
5	11.07
6	12.59
7	14.07
8	15.51
9	16.92
10	18.31

Distribución χ^2

TABLA Nº 6
DISTRIBUCIÓN χ^2

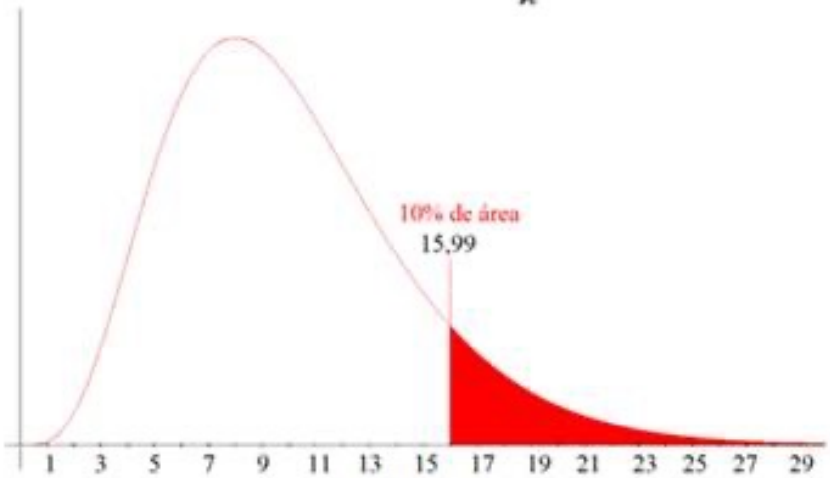

Ejemplo:
Para 10 grados de libertad
$P(\chi^2 > 15,99) = 0,10 = 10\%$

	0,995	0,990	0,975	0,950	0,900	0,750	0,500	0,250	0,100	**0,050**	0,025	0,010	0,005
1	0,000	0,000	0,001	0,004	0,016	0,102	0,455	1,323	2,706	3,841	5,024	6,635	7,879
2	0,010	0,020	0,051	0,103	0,211	0,575	1,386	2,773	4,605	5,991	7,378	9,210	10,597
3	0,072	0,115	0,216	0,352	0,584	1,213	2,366	4,108	6,251	7,815	9,348	11,345	12,838
4	0,207	0,297	0,484	0,711	1,064	1,923	3,357	5,385	7,779	9,488	11,143	13,277	14,860
5	0,412	0,554	0,831	1,145	1,610	2,675	4,351	6,626	9,236	11,070	12,833	15,086	16,750
6	0,676	0,872	1,237	1,635	2,204	3,455	5,348	7,841	10,645	12,592	14,449	16,812	18,548
7	0,989	1,239	1,690	2,167	2,833	4,255	6,346	9,037	12,017	14,067	16,013	18,475	20,278
8	1,344	1,646	2,180	2,733	3,490	5,071	7,344	10,219	13,362	15,507	17,535	20,090	21,955
9	1,735	2,088	2,700	3,325	4,168	5,899	8,343	11,389	14,684	16,919	19,023	21,666	23,589
10	2,156	2,558	3,247	3,940	4,865	6,737	9,342	12,549	15,987	18,307	20,483	23,209	25,188
11	2,603	3,053	3,816	4,575	5,578	7,584	10,341	13,701	17,275	19,675	21,920	24,725	26,757
12	3,074	3,571	4,404	5,226	6,304	8,438	11,340	14,845	18,549	**21,026**	23,337	26,217	28,300

Influencia de los olores en la concentración

Resultados basados en
Danuser, B., Moser, D., Vitale-Sethre, T., Hirsig, R., & Krueger, H. (2003). Performance in a Complex Task and Breathing under Odor Exposure. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, *45*(4), 549-562.

	Sin olor	Mal olor	Total
Aprueba	90	50	140
Falla	10	40	50
Total	100	90	190

Influencia de los olores en la concentración

	Sin olor	Mal olor	Total
Aprueba	90	50	140
Falla	10	40	50
Total	100	90	190

- Los resultados apoyan la idea de que los olores desagradables disminuyen el rendimiento, mostrando una asociación significativa entre la ejecución de la tarea y la presencia de olores desagradables, $\chi^2(1) = 28.98$, $p < .001$.

- En el grupo de control, un 90% de los participantes completó la tarea con éxito, pero el porcentaje de aprobación bajó a un 55% cuando las personas fueron expuestas a un olor desagradable.

χ^2: supuestos

1. La muestra es aleatoria
2. Las observaciones son independientes
3. El *n* es suficiente: las frecuencias esperadas deben ser mayores a 5 (aunque hay correcciones cuando esto no se cumple)

χ^2: extras

1. Una limitación importante es que no indica *donde* están las diferencias. Evaluar los descriptivos es fundamental en tablas de 3x2 o más.
2. A diferencias del coeficiente de r de pearson, χ^2 **no indica la magnitud** de la relacion, solo indica si están o no asociada las variables (por ser variables nominales u ordinales).

Veamos a un ejemplo

¿Existe asociación entre la zona en que se habita y mencionar la delincuencia como problema social?

Ejemplo χ^2: Delincuencia y zona habitacional

	Menciona	No menciona	Total
Urbano	731	589	1320
Rural	109	130	239
Total	840	719	

- Variable x: zona urbano/rural (categórica)
- Variable y: menciona delincuencia (categórica)
- Ho: Las variables son independientes/ No hay asociación
- Ha: Si hay asociación

Ejemplo χ^2: Delincuencia y zona habitacional

	Menciona	No menciona	Total
Urbano	731	589	1320
Rural	109	130	239
Total	840	719	1559

$$\text{Frecuencia esperada Urbano/Menciona} = \frac{1320 * 840}{1559} = 711{,}225$$

$$\text{Frecuencia esperada Urbano/No Menciona} = \frac{1320 * 719}{1559} = 608{,}774$$

$$\text{Frecuencia esperada Rural/Menciona} = \frac{239 * 840}{1559} = 128{,}774$$

$$\text{Frecuencia esperada Rural/No Menciona} = \frac{239 * 719}{1559} = 110{,}225$$

Ejemplo χ^2: Delincuencia y zona habitacional

	Menciona	No menciona	Total
Urbano	731 fe=711,22	589 fe=608,77	1320
Rural	109 fe=128,77	130 fe=110,22	239
Total	840	719	1559

$$\chi^2 = \sum \frac{(f_o - f_e)^2}{f_e}$$

$$\chi^2 = \frac{(731 - 711{,}22)^2}{711{,}22} + \frac{(589 - 608{,}77)^2}{608{,}77} + \frac{(109 - 128{,}77)^2}{128{,}77} + \frac{(130 - 110{,}22)^2}{110{,}22}$$

Ejemplo χ^2: Delincuencia y zona habitacional

	Menciona	No menciona	Total
Urbano	731 fe=711,22	589 fe=608,77	1320
Rural	109 fe=128,77	130 fe=110,22	239
Total	840	719	1559

$$\chi^2 = \sum \frac{(f_o - f_e)^2}{f_e}$$

$$\chi^2 = \frac{391{,}248}{711{,}22} + \frac{390{,}853}{608{,}77} + \frac{390{,}853}{128{,}77} + \frac{391{,}248}{110{,}22}$$

$$\chi^2 = 0{,}55 + 0{,}64 + 3{,}03 + 3{,}55 = 7{,}77$$

$\chi^2 = 7{,}77$ Grados de libertad= (j-1) * (i-1) = 1 * 1 = 1

Distribución c^2

Puntos de corte (equivalentes a $z = 1.96$)

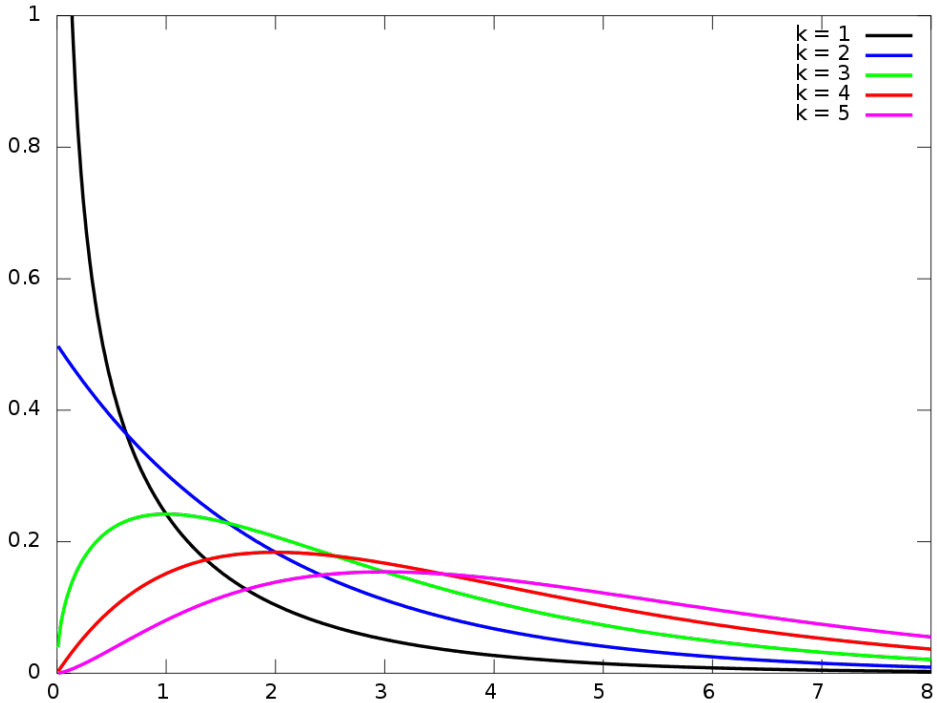

df	χ^2 (p = .05)
1	3.84
2	5.99
3	7.82
4	9.49
5	11.07
6	12.59
7	14.07
8	15.51
9	16.92
10	18.31

Distribución c^2

TABLA Nº 6
DISTRIBUCIÓN χ^2

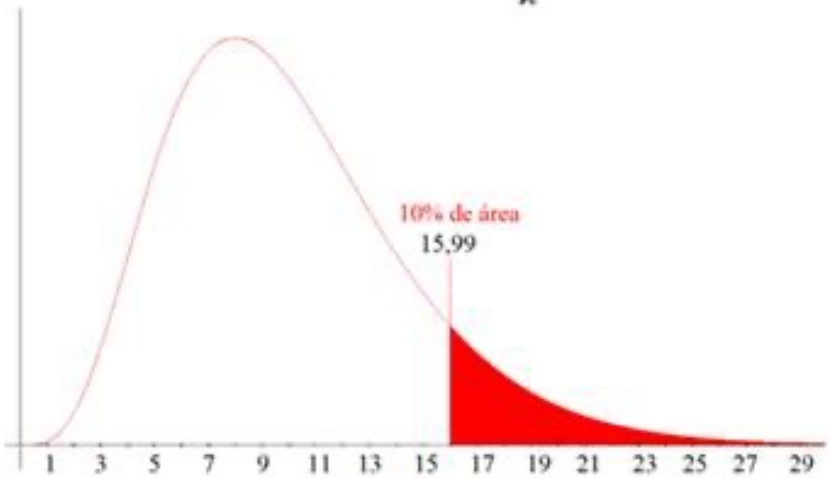

Ejemplo:
Para 10 grados de libertad
$$P(\chi^2 > 15,99) = 0,10 = 10\%$$

	0,995	0,990	0,975	0,950	0,900	0,750	0,500	0,250	0,100	**0,050**	0,025	0,010	0,005
1	0,000	0,000	0,001	0,004	0,016	0,102	0,455	1,323	2,706	3,841	5,024	6,635	7,879
2	0,010	0,020	0,051	0,103	0,211	0,575	1,386	2,773	4,605	5,991	7,378	9,210	10,597
3	0,072	0,115	0,216	0,352	0,584	1,213	2,366	4,108	6,251	7,815	9,348	11,345	12,838
4	0,207	0,297	0,484	0,711	1,064	1,923	3,357	5,385	7,779	9,488	11,143	13,277	14,860
5	0,412	0,554	0,831	1,145	1,610	2,675	4,351	6,626	9,236	11,070	12,833	15,086	16,750
6	0,676	0,872	1,237	1,635	2,204	3,455	5,348	7,841	10,645	12,592	14,449	16,812	18,548
7	0,989	1,239	1,690	2,167	2,833	4,255	6,346	9,037	12,017	14,067	16,013	18,475	20,278
8	1,344	1,646	2,180	2,733	3,490	5,071	7,344	10,219	13,362	15,507	17,535	20,090	21,955
9	1,735	2,088	2,700	3,325	4,168	5,899	8,343	11,389	14,684	16,919	19,023	21,666	23,589
10	2,156	2,558	3,247	3,940	4,865	6,737	9,342	12,549	15,987	18,307	20,483	23,209	25,188
11	2,603	3,053	3,816	4,575	5,578	7,584	10,341	13,701	17,275	19,675	21,920	24,725	26,757
12	3,074	3,571	4,404	5,226	6,304	8,438	11,340	14,845	18,549	**21,026**	23,337	26,217	28,300

En R: librería gmodels

```
CrossTable(c65$zona,c65$memdelin, prop.chisq = TRUE, expected=TRUE, chisq = F, prop.r=FALSE, prop.c=F,
           prop.t=F, fisher=FALSE, mcnemar=FALSE,
           resid=FALSE, sresid=FALSE, asresid=FALSE,
           missing.include=FALSE)
```

```
##
##
##    Cell Contents
## |-------------------------|
## |                       N |
## |              Expected N |
## | Chi-square contribution |
## |-------------------------|
##
##
## Total Observations in Table:  1559
##
##
##              | c65$memdelin
##     c65$zona |    Menciona | No menciona |   Row Total |
## -------------|-------------|-------------|-------------|
##       Urbano |         731 |         589 |        1320 |
##              |     711.225 |     608.775 |             |
##              |       0.550 |       0.642 |             |
## -------------|-------------|-------------|-------------|
##        Rural |         109 |         130 |         239 |
##              |     128.775 |     110.225 |             |
##              |       3.037 |       3.548 |             |
## -------------|-------------|-------------|-------------|
## Column Total |         840 |         719 |        1559 |
## -------------|-------------|-------------|-------------|
##
##
## Statistics for All Table Factors
##
##
## Pearson's Chi-squared test
## ------------------------------------------------------------
## Chi^2 =  7.776514     d.f. =  1     p =  0.005292982
```

En R básico

```
#Calcular tabla
x=table(c65$zona,c65$memdelin)

x
```

```
##
##          Menciona No menciona
##   Urbano      731         589
##   Rural       109         130
```

```
#Test de Pearon de Chi cuadrado usando commando
chisq.test(x, correct=FALSE)
```

```
##
##  Pearson's Chi-squared test
##
## data:  x
## X-squared = 7.7765, df = 1, p-value = 0.005293
```

χ^2: supuestos

1. La muestra es aleatoria
2. Las observaciones son independientes
3. El *n* es suficiente: las frecuencias esperadas deben ser mayores a 5 (aunque hay correcciones cuando esto no se cumple)

χ^2: extras

1. Una limitación importante es que no indica *donde* están las diferencias. Evaluar los descriptivos es fundamental en tablas de 3x2 o más.
2. A diferencias del coeficiente de r de pearson, χ^2 **no indica la magnitud** de la relacion, solo indica si están o no asociada las variables (por ser variables nominales u ordinales).

Resumiendo Prueba χ^2

- Usado para analizar tablas de cruce de variables.
- La Hipótesis nula es que las variables no se asocian.
- Para esto, se calculan las frecuencias esperadas para la tabla.
- Una frecuencia esperada corresponde “al número de casos esperados en cada celda de la tabla cuando no hay asociación entre las variables”.
- Se calcula de la siguiente forma:

$$\chi^2 = \sum \frac{\left(f_o - f_e\right)^2}{f_e}$$

Correlación

Asociación entre variables

La mayoría de los análisis que vamos a ver en el curso son formas de evaluar el grado de asociación entre dos variables. Es decir, si la variabilidad en una está asociada con la variabilidad en otra.

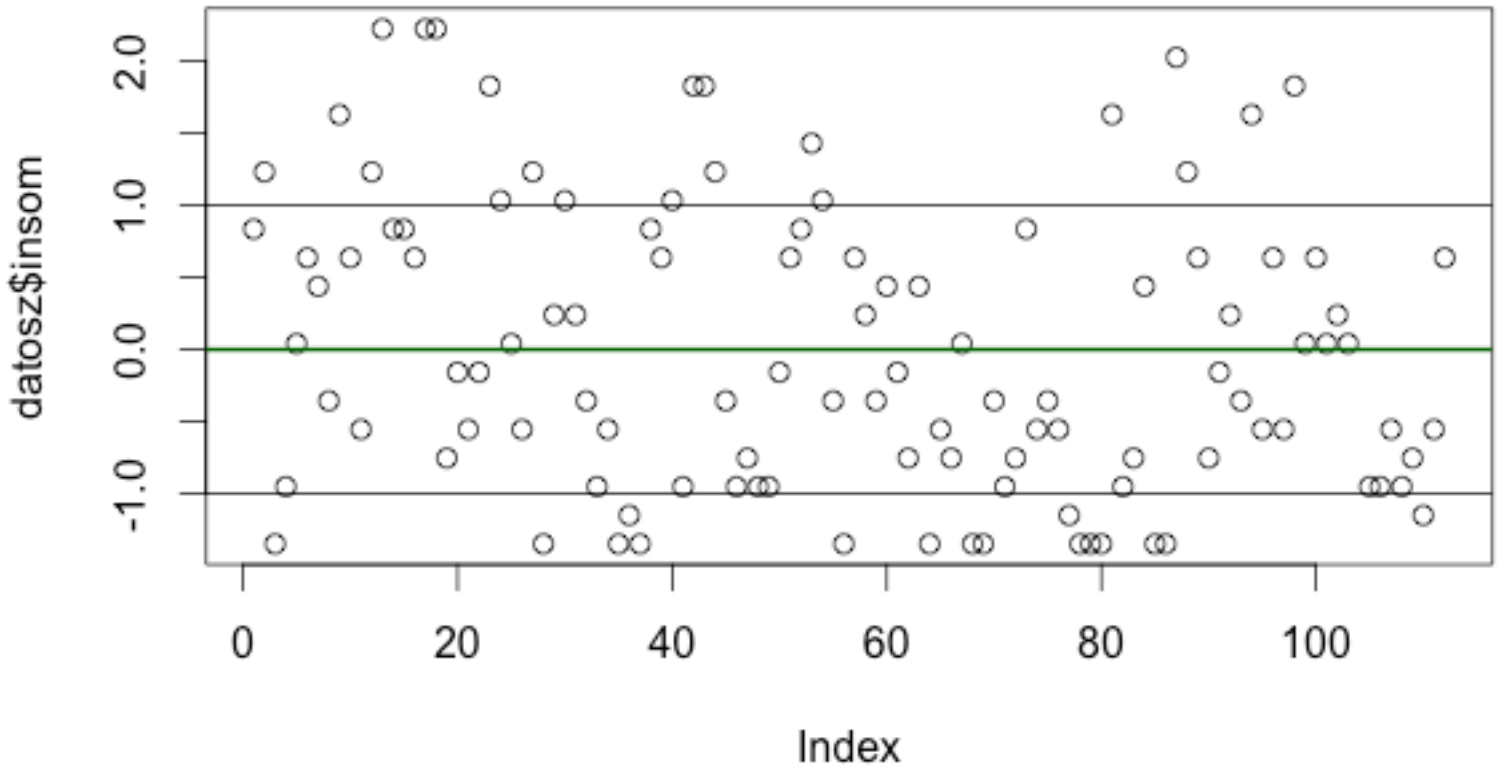

Asociación de variables

- Podemos ver como se "combinan" los puntajes de cada una de mis variables independientes con la variable dependiente, por medio de dispersiogramas.
- En un dispersiograma cada punto refleja la combinación de ambos puntajes para cada sujeto
- *¿Sigue siendo el promedio de la variable dependiente un buen modelo?*

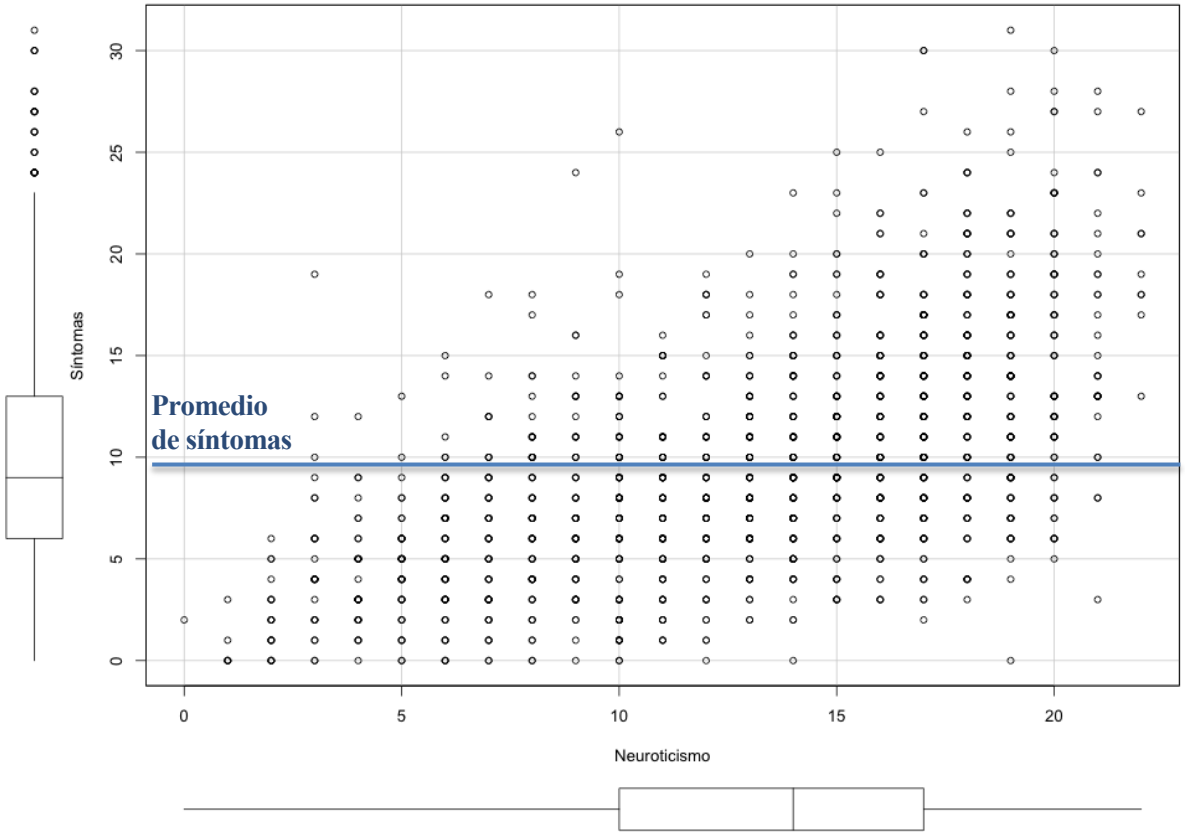

Asociación de variables

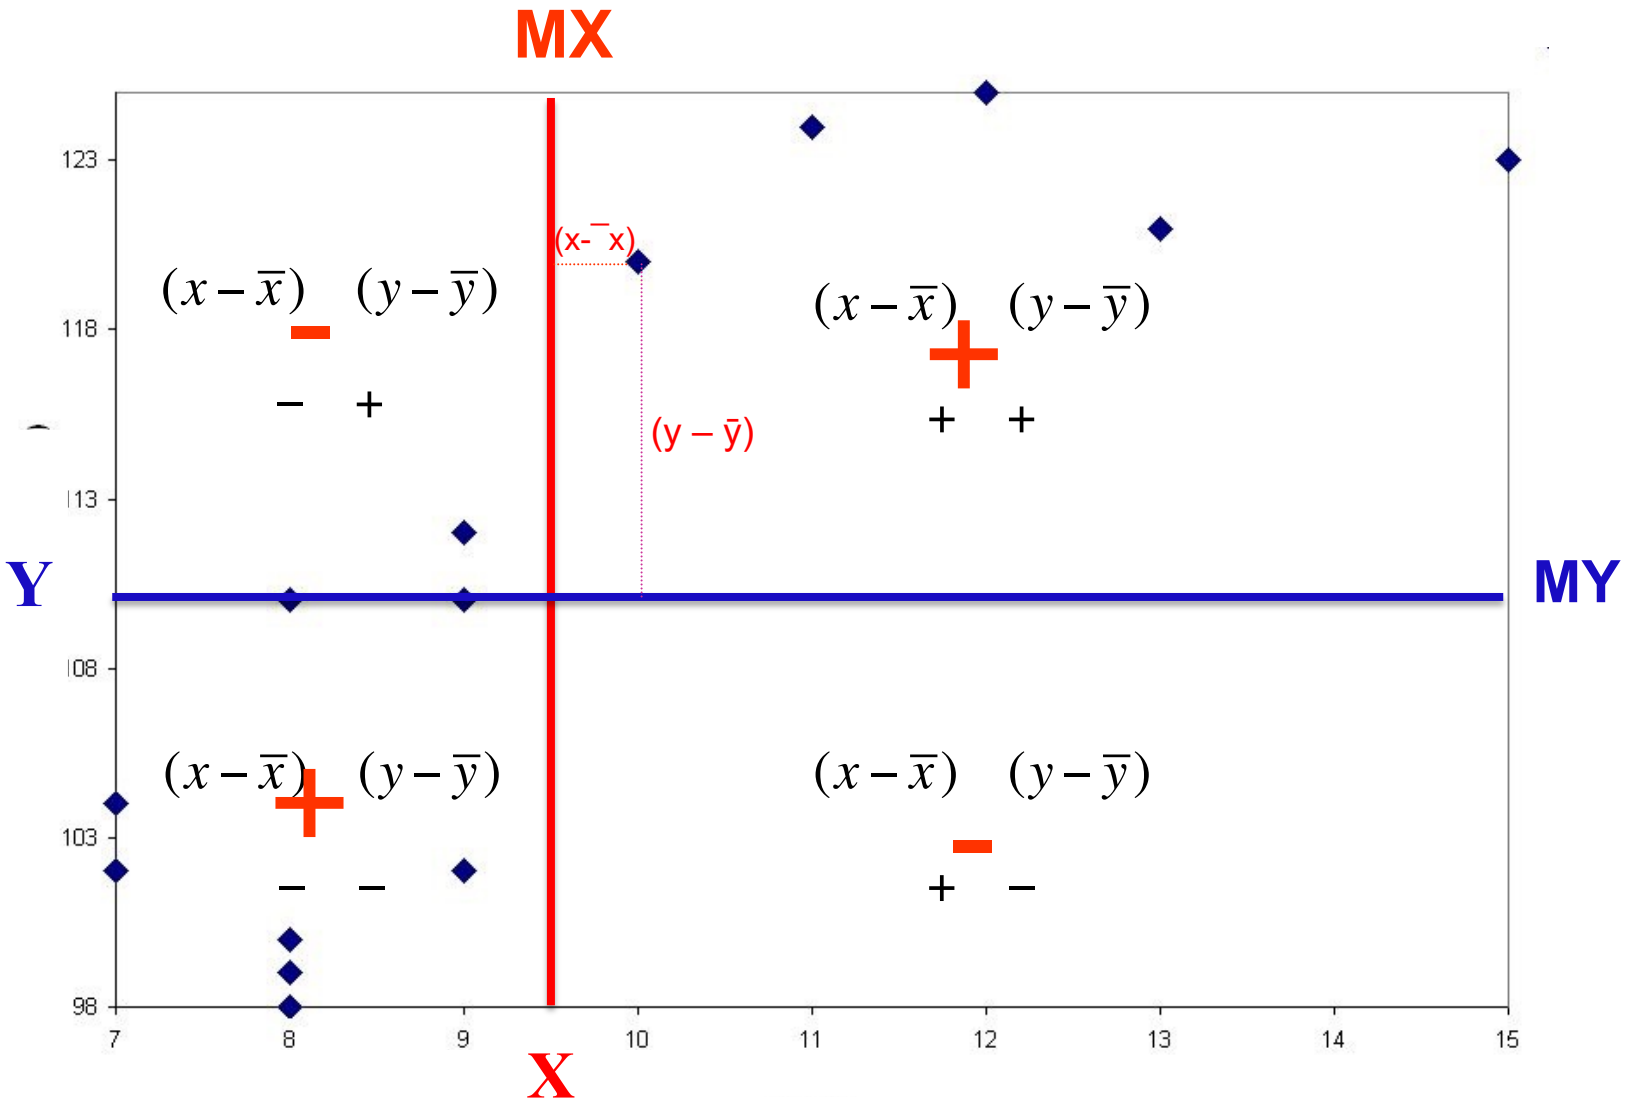

Asociación de variables

- **Covarianza:** mide la variación conjunta de dos variables, pero es afectada por los cambios de unidades de medida

$$s_{xy} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})\cdot(y - \overline{y})}{n} = \frac{1}{n}\cdot\sum_{i=1}^{n} x_i \cdot y_i - \overline{x}\cdot\overline{y}$$

- **La correlación:** estandariza la covarianza

$$r_{xy} = \frac{s_{xy}}{s_x \cdot s_y}$$

Tamaño de la relación

- Dado que es una medida estandarizada, el signo indica la dirección de la relación (positiva o negativa)
- El valor indica el monto o magnitud de la relación (desde ausencia de relación, débil o fuerte)
- Los valores posibles para una correlación van entre -1 (correlación perfecta negativa) y +1 (correlación perfecta positiva). Si obtienen un número fuera de este rango, ¡algo salió mal!
- En general, en ciencias sociales:

  - Ausencia de relación lineal $= 0$
  - Relación pequeña ≥ 0.1
  - Relación mediana ≥ 0.3
  - Relación fuerte ≥ 0.5

Correlaciones positivas y negativas

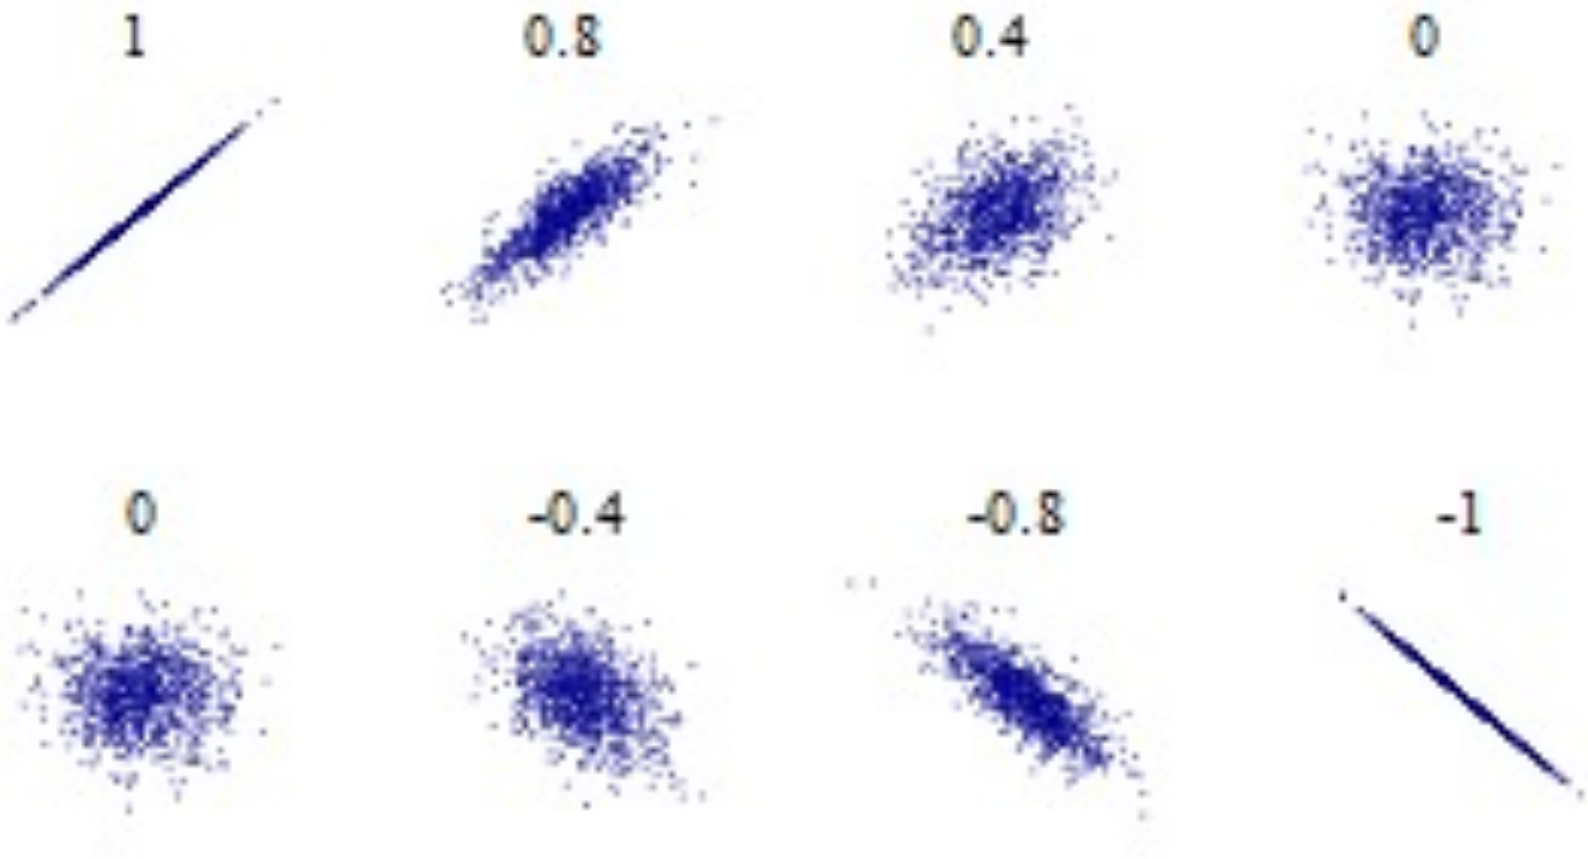

¿Cómo sabemos si la correlación es significativa?

t es el estimador dividido por el error estándar del estimador

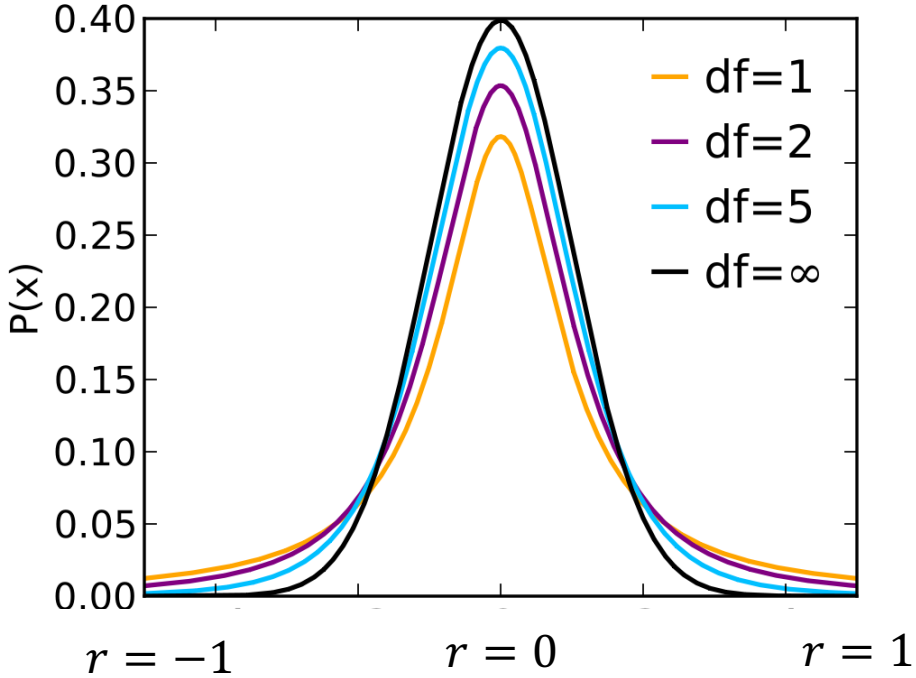

$$t = {}^{r}\Big/\sqrt{\frac{1 - r^2}{n - 2}}$$

Una correlación entre dos variables tiene $n - 2$ grados de libertad

Al igual que en una prueba t, pueden ocupar un contraste unilateral si tienen una hipótesis clara sobre la dirección de la relación

```
with(estudio2013,
     cor.test(comp, anseval))

      Pearson's product-moment correlation

data:  comp and anseval
t = 2.9139, df = 133, p-value = 0.004189
alternative hypothesis: true correlation is not
equal to 0
95 percent confidence interval:
 0.07929096 0.39747257
sample estimates:
      cor
0.2449663
```

Las personas con mayores niveles de competitividad académica tienden a reportar mayores niveles de ansiedad ante evaluaciones ($r = .24$, $p < .01$).

r^2 Varianza Explicada (o compartida)

- Si las variables están relacionadas, quiere decir que tienen varianza en común

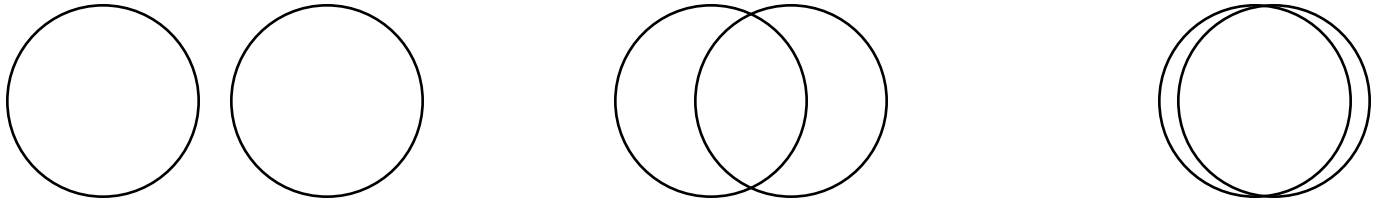

$r_{xy} = 0$ $\quad$ $r_{xy} = 0.71$ $\quad$ $r_{xy} = 0.98$

Competitividad académica y ansiedad ante evaluaciones comparten un 5.8% de varianza.

Simplemente hay que elevar *r* al cuadrado y multiplicar por 100 ($r = .24$, $r^2 = .058$ o expersado en porcentaje es 5.8%).

Varianza explicada

$r = 0.1$ → Relación pequeña → $r^2 = 0.01$ → 1%

$r = 0.3$ → Relación mediana → $r^2 = 0.09$ → 9%

$r = 0.5$ → Relación fuerte → $r^2 = 0.25$ → 25%

¿Logro en lenguaje se relaciona con logro en conocimiento cívico?

```
### Civic Knowledge and Reading Test
civic <- ggplot(mergeita, aes(ital, pv1civ))
civic + ylim(200, 800)+
  xlim(100,350)+
  geom_hline(yintercept=524, linetype="dashed", color = "red")+
  geom_vline(xintercept=202, linetype="dashed", color = "red")+
  geom_point()+
  #facet_wrap(~ study) +
  labs(x = "Reading test", y = "Civic knowledge")
```

```
## Warning: Removed 520817 rows containing missing values (geom_point).
```

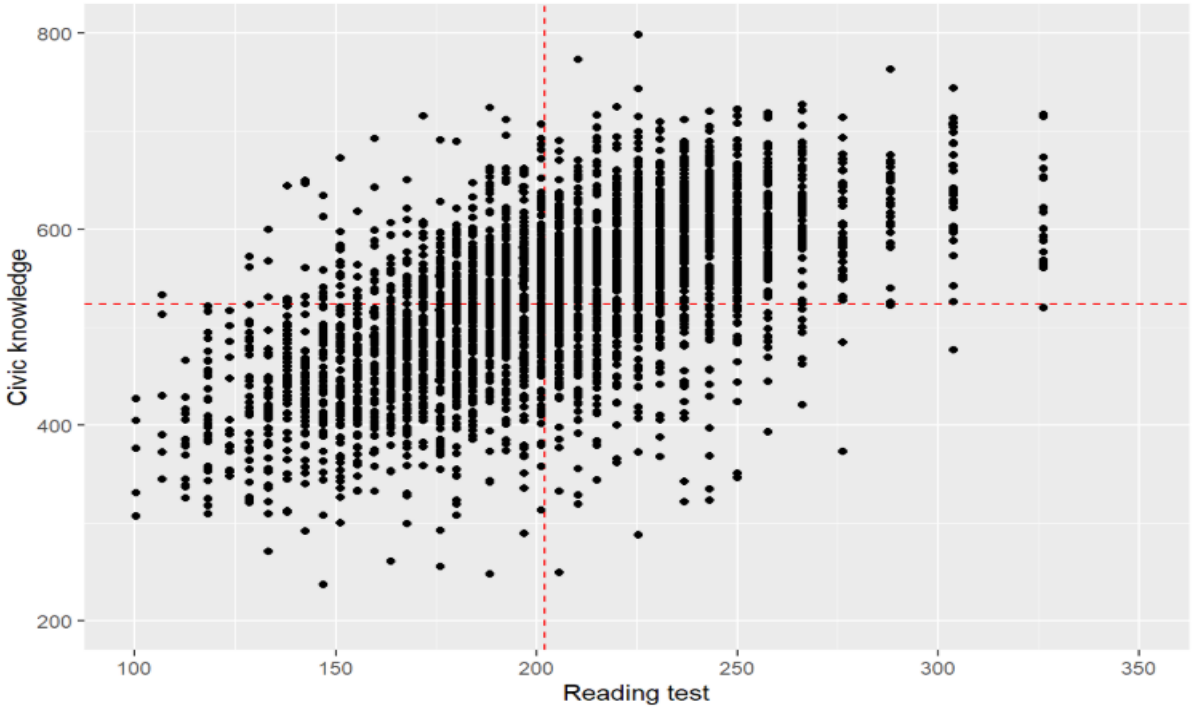

```
cor.test(mergeita$ital, mergeita$pv1civ)
```

```
##
##  Pearson's product-moment correlation
##
## data:  mergeita$ital and mergeita$pv1civ
## t = 44.386, df = 3341, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.5872793 0.6299482
## sample estimates:
##       cor
## 0.6090542
```

Los estudiantes con mayores niveles de logro en la prueba de lenguaje tienden a obtener mayores niveles en la prueba de conocimiento cívico ($r_{(3341)} = .61$, $p < .01$).

¿Cómo sabemos si la correlación es significativa?

t es el estimador dividido por el error estándar del estimador

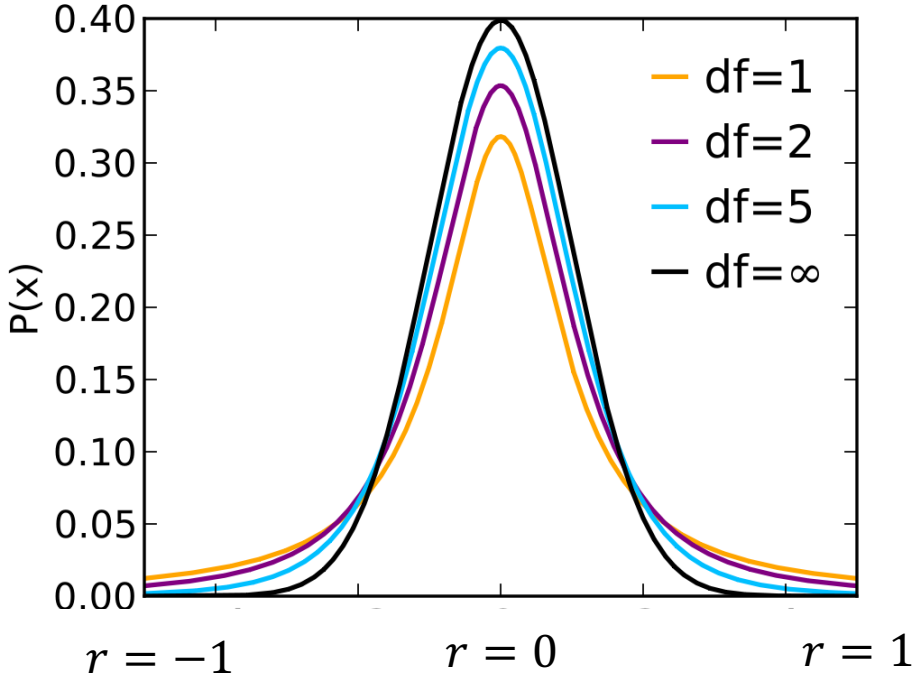

$$t = r \Big/ \sqrt{\frac{1 - r^2}{n - 2}}$$

Una correlación entre dos variables tiene $n - 2$ grados de libertad

Al igual que en una prueba t, pueden ocupar un contraste unilateral si tienen una hipótesis clara sobre la dirección de la relación

¿Cómo sabemos si la correlación es significativa?

$$t = {}^{r}\Big/\sqrt{\frac{1-r^2}{n-2}}$$

t es el estimador dividido por el error estándar del estimador

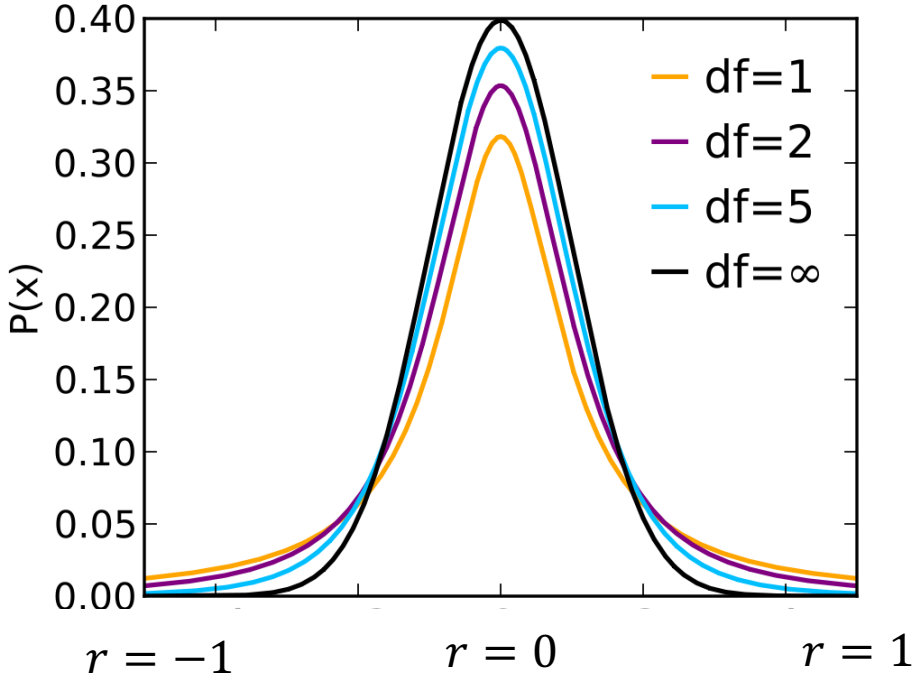

$$t = \frac{0{,}6090542}{\sqrt{\frac{1-0{,}372}{3443-2}}} = 44.386$$

Una correlación entre dos variables tiene $n - 2$ grados de libertad

Al igual que en una prueba t, pueden ocupar un contraste unilateral si tienen una hipótesis clara sobre la dirección de la relación

r^2 Varianza Explicada (o compartida)

- Si las variables están relacionadas, quiere decir que tienen varianza en común

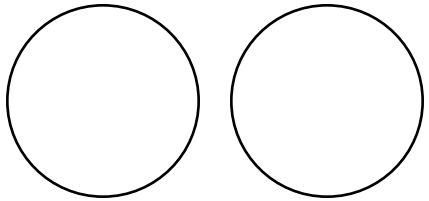

$r_{xy} = 0$

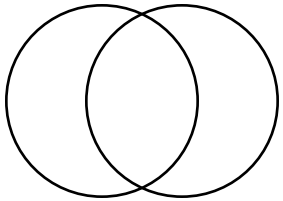

$r_{xy} = 0.71$

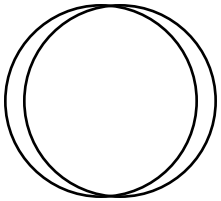

$r_{xy} = 0.98$

Logro en lenguaje y logro en cívica comparten un 37,2% de varianza.

Simplemente hay que elevar *r* al cuadrado y multiplicar por 100 ($r = .61$, $r^2 = .372$ o expersado en porcentaje es 37,2%).

Varianza explicada

$r = 0.1$ → Relación pequeña → $r^2 = 0.01$ → 1%

$r = 0.3$ → Relación mediana → $r^2 = 0.09$ → 9%

$r = 0.5$ → Relación fuerte → $r^2 = 0.25$ → 25%

Regresión Lineal

Regresión lineal

¿Para qué sirve?

- Vimos que con la Correlación podemos saber cuán fuertemente están relacionadas las variables **x** e **y** entre ellas.
- ¿Pero podemos estimar el valor de **y** a partir de los los valores de **x**? ¿O cuánto cambiará **y**, si **x** cambia en una unidad?
- Este es el concepto de regresion.

Regresión Lineal Simple

- La Regresión Lineal simple sirve para predecir una variable, sabiendo cómo se comporta la otra.
- Esto lo hace a partir de la recta de regresión, en torno a la cual, se ajustan los datos con las distancias cuadráticas mínimas.
- Esta recta (línea) de regresión representa la mejor solución estimada para predecir los datos (variable dependiente) a partir de las variables independiente: ***línea o recta con el mejor ajuste***.

Regresión lineal

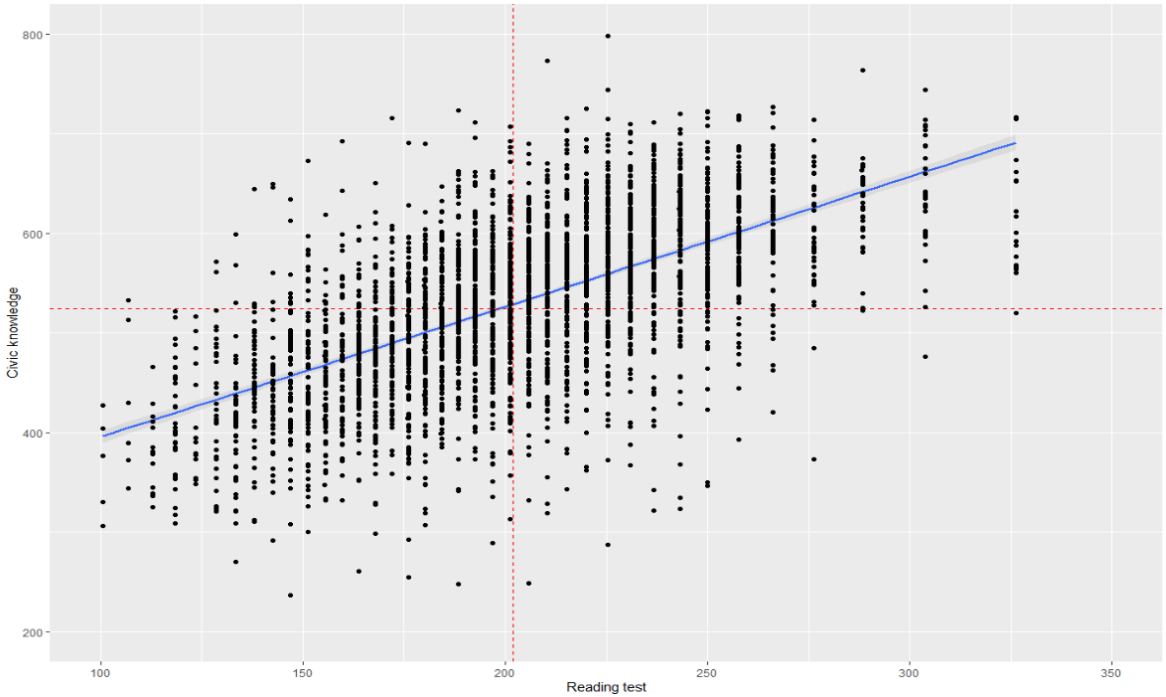

El análisis de regresión calcula una ecuación de la recta con los parámetros que mejor se ajustan a los datos.

$$Yi = constante + \beta 1 * x + error$$

En este caso, los niveles de logro en lenguaje predicen significativamente logro en cívica ($\beta = 1.30$, $p < .05$).

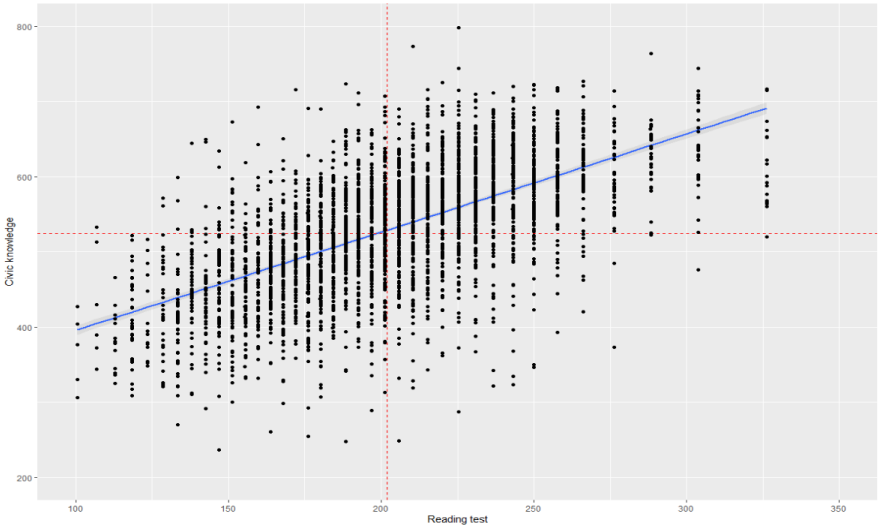

Ecuación de Regresión

- El análisis de Regresión lineal nos entrega también una ***ecuación de regresión***, una fórmula, que describe a la recta o línea de regresión.
- Esta ecuación de regresión se basa en la **ecuación de la recta: $y = a + bx$**

Ecuación de Regresión

- Entonces la ecuación de la recta sería

$$\mathbf{y = a + bx + \bar{e}}$$
$$Y_1 = \beta_0 + \beta_1 * x_1 + e_i$$

Donde:

- Y_1 es la variable dependiente
- x_1 son las variables independientes
- e_i es el error asociado a la estimación de Y (error de estimación individual)
- El parámetro β_0 es el intercepto (Valor de Y cuando los X = 0)
- β_1 son las pendientes estimadas. Que indican cuanto cambia, en promedio, Y ante el cambio de una unidad de X (considerando todas las otras X del modelo como constantes, Seteris Paribus, cuando hay otros predictores)

Indicadores de Regresión.

Un ejemplo

- **Queremos evaluar en qué medida las habilidades de lectura, el nivel educacional de los padres o la presencia de libros en el hogar se asocian con mayores niveles de conocimiento cívico.**

- **Variable dependiente: ¿?**
- **Variables independientes: ¿?**

Un ejemplo

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
pv1civ	0	1	529.42	84.03	142.15	473.77	534.71	588.80	798.44	
ital	0	1	201.85	39.62	54.95	176.00	201.23	225.36	326.24	
s_hisced	0	1	2.37	1.03	0.00	2.00	2.00	3.00	4.00	
s_homlit	0	1	2.22	1.24	0.00	1.00	2.00	3.00	4.00	

Exploración gráfica

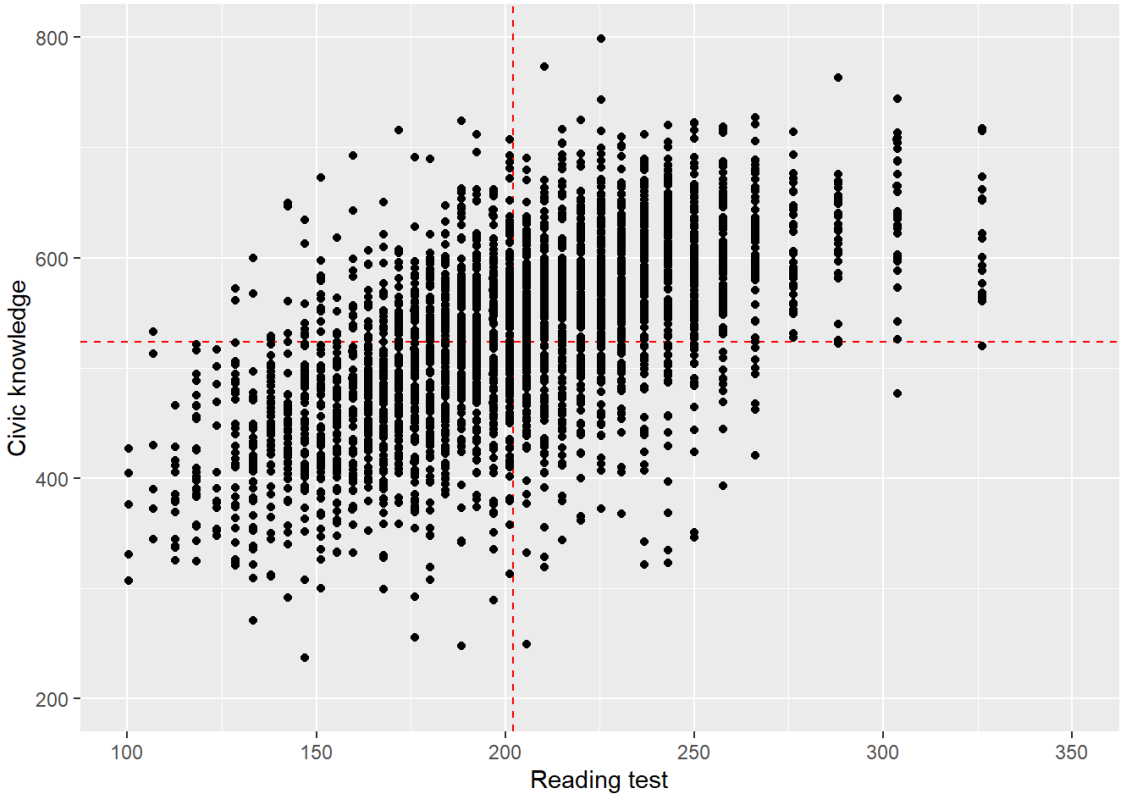

Exploración correlacional

```
cor.test(mergeita$ital, mergeita$pv1civ)
```

```
##
##  Pearson's product-moment correlation
##
## data:  mergeita$ital and mergeita$pv1civ
## t = 44.178, df = 3278, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.5889896 0.6319126
## sample estimates:
##       cor
## 0.6108998
```

Exploración correlacional

```r
cor(mergeita, method= "pearson")
```

```
##            pv1civ      ital  s_hisced  s_homlit
## pv1civ   1.0000000 0.6108998 0.2370928 0.3583889
## ital     0.6108998 1.0000000 0.1920799 0.3128672
## s_hisced 0.2370928 0.1920799 1.0000000 0.3640371
## s_homlit 0.3583889 0.3128672 0.3640371 1.0000000
```

```r
res2 <- rcorr(as.matrix(mergeita))
res2
```

```
##          pv1civ ital s_hisced s_homlit
## pv1civ     1.00 0.61     0.24     0.36
## ital       0.61 1.00     0.19     0.31
## s_hisced   0.24 0.19     1.00     0.36
## s_homlit   0.36 0.31     0.36     1.00
##
## n= 3280
##
##
## P
##          pv1civ ital s_hisced s_homlit
## pv1civ           0    0        0
## ital      0      0    0        0
## s_hisced  0      0             0
## s_homlit  0      0    0
```

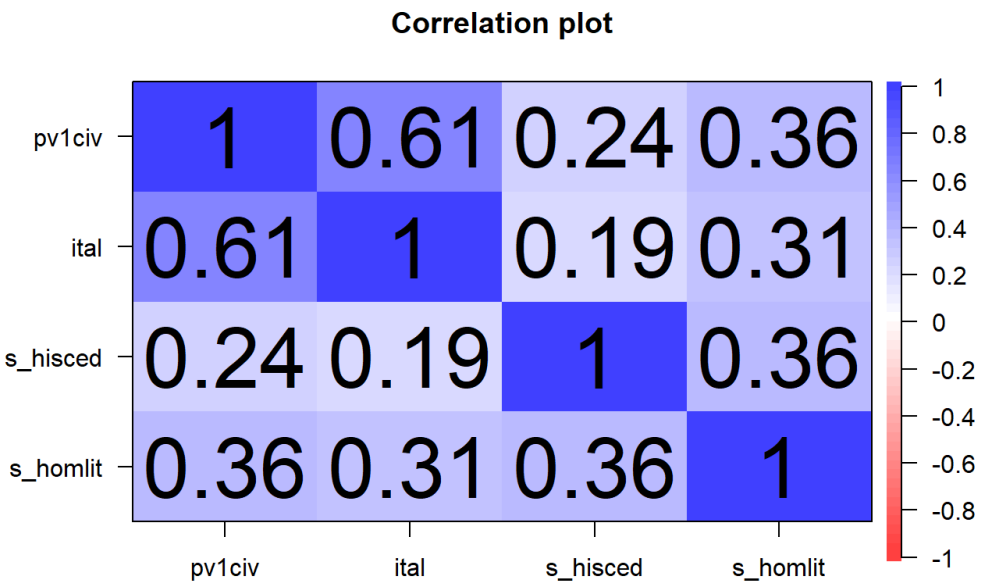

Estimación de regresión lineal simple

```
int=lm(pv1civ~ ital , data=mergeita)
summary(int)
```

```
##
## Call:
## lm(formula = pv1civ ~ ital, data = mergeita)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -355.05  -40.07    3.77   44.34  238.56
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 267.85439    6.03351   44.39   <2e-16 ***
## ital          1.29583    0.02933   44.18   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 66.54 on 3278 degrees of freedom
## Multiple R-squared:  0.3732, Adjusted R-squared:  0.373
## F-statistic:  1952 on 1 and 3278 DF,  p-value: < 2.2e-16
```

- **Coeficiente de determinación R^2 :** En la regresión simple es igual al cuadrado del coeficiente de correlación de Pearson y expresa la **proporción de la varianza** de la variable dependiente que se encuentra explicada por la variable independiente.

- Se calcula mediante la fórmula : **R^2 = 1- (Suma cuadrado de los residuos / Suma cuadrado total)**

- **Coeficiente de determinación R^2 corregido:** Corrección realizada a R^2 teniendo en cuenta el **número de casos** (un bajo número de casos en la muestra podría generar un R^2 «inflado» no representativo de la muestra población) y de **variables independientes** (para el caso de la regresión simple siempre es una sola).
- Este es el coeficiente que concretamente se considera dado que ya viene con la corrección del tamaño muestral.

Estimación de regresión lineal simple

```
int=lm(pv1civ~ ital , data=mergeita)
summary(int)
```

```
##
## Call:
## lm(formula = pv1civ ~ ital, data = mergeita)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -355.05  -40.07    3.77   44.34  238.56
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 267.85439    6.03351   44.39   <2e-16 ***
## ital          1.29583    0.02933   44.18   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 66.54 on 3278 degrees of freedom
## Multiple R-squared:  0.3732, Adjusted R-squared:  0.373
## F-statistic:  1952 on 1 and 3278 DF,  p-value: < 2.2e-16
```

- **ANOVA del modelo:** Mediante la interpretación del **estadístico F** se puede determinar si existe una relación estadísticamente significativa entre las variables , poniendo a prueba la **hipótesis nula de que el valor poblacional de R es igual a 0**. Si el nivel de significancia es = .000 , indica que el valor de R es distinto de 0 y que las variables se encuentran linealmente relacionadas.

- F(1,3278)= 1952; p<0.001. Esto indica que el modelo de regresión explica más que los residuos (R mayor a 0).

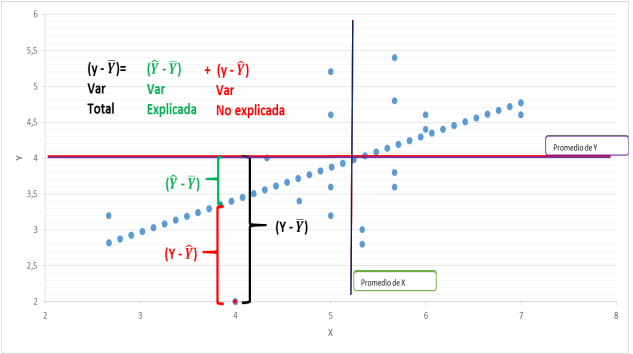

Tabla Distribución F

Grados de libertad para el denominador	Grados de libertad para el numerador															
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40
1	161	200	216	225	230	234	237	239	241	242	244	246	248	249	250	251
2	18.5	19.0	19.2	19.2	19.3	19.3	19.4	19.4	19.4	19.4	19.4	19.4	19.4	19.5	19.5	19.5
3	10.1	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70	8.66	8.64	8.62	8.59
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86	5.80	5.77	5.75	5.72
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62	4.56	4.53	4.50	4.46
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94	3.87	3.84	3.81	3.77
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51	3.44	3.41	3.38	3.34
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22	3.15	3.12	3.08	3.04
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01	2.94	2.90	2.86	2.83
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.85	2.77	2.74	2.70	2.66
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.72	2.65	2.61	2.57	2.53
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62	2.54	2.51	2.47	2.43
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.53	2.46	2.42	2.38	2.34
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.46	2.39	2.35	2.31	2.27
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40	2.33	2.29	2.25	2.20
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.35	2.28	2.24	2.19	2.15
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.31	2.23	2.19	2.15	2.10
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.27	2.19	2.15	2.11	2.06
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.31	2.23	2.16	2.11	2.07	2.03
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.28	2.20	2.12	2.08	2.04	1.99
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.25	2.18	2.10	2.05	2.01	1.96
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.23	2.15	2.07	2.03	1.98	1.94
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.20	2.13	2.05	2.01	1.96	1.91
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.18	2.11	2.03	1.98	1.94	1.89
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28	2.24	2.16	2.09	2.01	1.96	1.92	1.87
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.09	2.01	1.93	1.89	1.84	1.79
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	2.00	1.92	1.84	1.79	1.74	1.69
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04	1.99	1.92	1.84	1.75	1.70	1.65	1.59
120	3.92	3.07	2.68	2.45	2.29	2.18	2.09	2.02	1.96	1.91	1.83	1.75	1.66	1.61	1.55	1.50
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88	1.83	1.75	1.67	1.57	1.52	1.46	1.39

Estimación de regresión lineal simple

```
int=lm(pv1civ~ ital , data=mergeita)
summary(int)
```

```
##
## Call:
## lm(formula = pv1civ ~ ital, data = mergeita)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -355.05  -40.07    3.77   44.34  238.56
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 267.85439    6.03351   44.39   <2e-16 ***
## ital          1.29583    0.02933   44.18   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 66.54 on 3278 degrees of freedom
## Multiple R-squared:  0.3732, Adjusted R-squared:  0.373
## F-statistic:  1952 on 1 and 3278 DF,  p-value: < 2.2e-16
```

- **Ecuación de la recta (coeficientes de regresión)**

$$Y_i = \beta_0 + \beta_1 * x_1$$

- **Intercepto (constante):** Constituye el valor inicial de la recta de regresión ó β_0 a partir desde puntuaciones directas. Es el intercepto de la recta.
  - **267.85 (t=44.39; p<0.001)**

- **Pendiente (β_1):** Corresponde a la pendiente de la línea de regresión o β_1, lo que en concreto indica cuánto cambia en promedio la VD por cada unidad que cambia la VI.
  - **1.29 (t=44.18; p<0.001)**

CCIV=
267.85 +
1.29x(puntos de lenguaje)

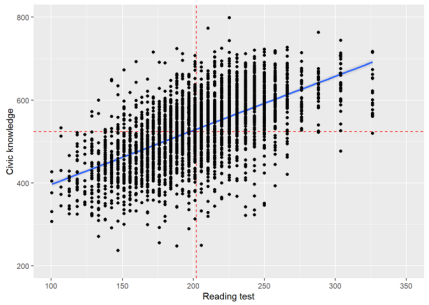

Estimación de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 * x_1$$

$$Y_i = 267{,}85 + 1{,}29 * x$$

Usando la ecuación de la recta, ¿cuantos puntos en conocimiento cívico obtendría un estudiante que obtiene 100 puntos en la prueba de lenguaje?

$$Y_i = 267{,}85 + 1{,}29 * 100 = 396{,}85$$

Usando la ecuación de la recta, ¿cuantos puntos en conocimiento cívico obtendría un estudiante que obtiene 200 puntos en la prueba de lenguaje?

$$Y_i = 267{,}85 + 1{,}29 * 200 = 525{,}85$$

Usando la ecuación de la recta, ¿cuantos puntos en conocimiento cívico obtendría un estudiante que obtiene 300 puntos en la prueba de lenguaje?

$$Y_i = 267{,}85 + 1{,}29 * 300 = 654{,}85$$

Estimación de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 * x_1$$

$$Y_i = 267{,}85 + 1{,}29 * x$$

Usando la e co
obtendría u nguaje?

$$Y_i = 267{,}85 + 1{,}29 * 100 = 396{,}85$$

Usando la e co
obtendría u nguaje?

$$Y_i = 267{,}85 + 1{,}29 * 200 = 525{,}85$$

Usando la e co
obtendría u nguaje?

$$Y_i = 267{,}85 + 1{,}29 * 300 = 654{,}85$$

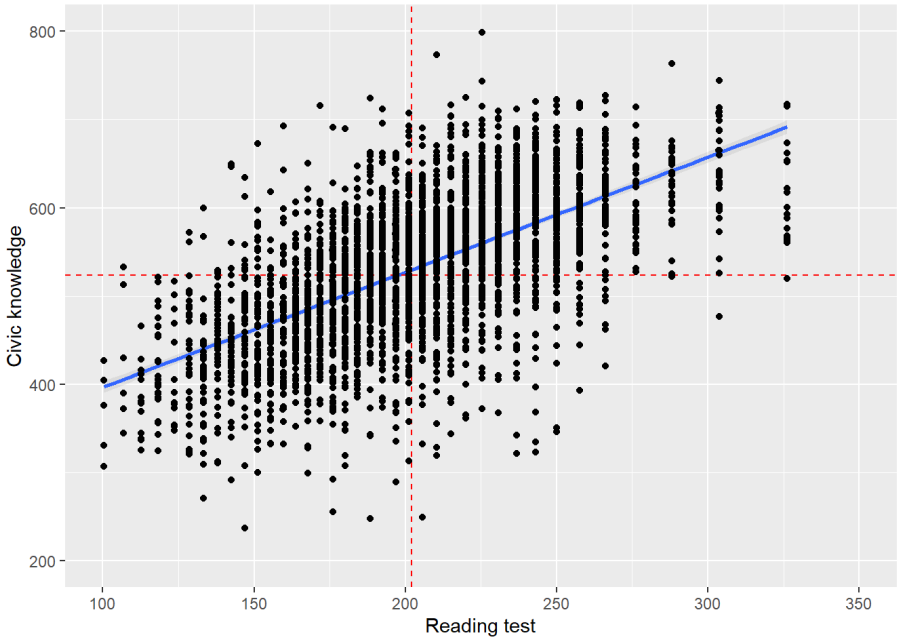

Estimación de regresión lineal simple

```
int=lm(pv1civ~ ital , data=mergeita)
summary(int)
```

```
##
## Call:
## lm(formula = pv1civ ~ ital, data = mergeita)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -355.05  -40.07    3.77   44.34  238.56
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 267.85439    6.03351   44.39   <2e-16 ***
## ital          1.29583    0.02933   44.18   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 66.54 on 3278 degrees of freedom
## Multiple R-squared:  0.3732, Adjusted R-squared:  0.373
## F-statistic:  1952 on 1 and 3278 DF,  p-value: < 2.2e-16
```

- **Pendiente estandarizada** (β_1)**:** Definen la ecuación de regresión una vez que los puntajes directos u observados de ambas variables son transformados en puntuaciones típicas o estandarizadas. Corresponde a cuántas desviaciones estándar cambia la VD cuando la VI cambia en 1 desviación estándar.

- Como obtener los coeficientes Beta: $\beta_1 = B_1\ (S_x / S_y)$

- Igualdad solo válida para la regresión simple
  - Coeficiente $\beta_1 = r$ (Coeficiente de correlación de Pearson entre las variables). También mantiene el signo que informa acerca de la dirección de la relación

```
lm.beta(int)
```

```
##      ital
## 0.6108998
```

Estimación de regresión lineal simple

```
int=lm(pv1civ~ s_hisced , data=mergeita)
summary(int)
```

```
##
## Call:
## lm(formula = pv1civ ~ s_hisced, data = mergeita)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -380.17  -55.83    5.32   57.59  256.72
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  483.497      3.582  134.97   <2e-16 ***
## s_hisced      19.409      1.389   13.97   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 81.65 on 3278 degrees of freedom
## Multiple R-squared:  0.05621,    Adjusted R-squared:  0.05593
## F-statistic: 195.2 on 1 and 3278 DF,  p-value: < 2.2e-16
```

$$Y_i = 267{,}85 + 1{,}29 * x$$

Usando la ecuación de la recta, ¿cuantos puntos en conocimiento cívico obtendría un estudiante que proviene de una familia con el máximo nivel educacional (4)?

$$Y_i = 483{,}497 + 19{,}409 * 4 = 561{,}133$$