

Metodologías Cuantitativas de Investigación en Psicología I

Sesión 11: Regresión Múltiple

Las medidas de asociación:

- Evalúan la variación conjunta de dos variables.
- Según los niveles de medición, podemos distinguir distintos tipos de medidas de asociación.

	Intervalar	Ordinal	Nominal
Intervalar	Correlación Pearson	Anova	T-test / Anova
Ordinal	Anova	Chi-cuadrado	Chi-cuadrado
Nominal	T-test / Anova	Chi-cuadrado	Chi-cuadrado

Las medidas de asociación:

Considerando la correlación como la medida de asociación principal, existen varios coeficientes de correlación, según el niveles de medición.

- r_{Pearson} es la versión paramétrica. Asume variables continuas y normalidad.
- r_{Spearman} es una versión no paramétrica. Se usa para variables ordinales.
- $r_{\text{PointBiserial}}$ y r_{biserial} cuantifican la relación entre una variable continua y dicotómica.
- $r_{\text{policóricas}}$ es una alternativa que permite diferentes niveles de medición entre las variables (p.e. cuadracóricas, tetracóricas, policóricas)

Correlación

¿Cómo evaluar la relación entre dos variables con un niveles de medición continuo?

Por ejemplo, la relación entre el logro y recursos de los participantes.

Para evaluar esta relación:

- Se midió el nivel de logro en notas
- Se evaluó el nivel de Estatus

Correlación

- ¿Cómo evaluar si hay asociación entre éstas dos variables?

Logro (Y)	Estatus (X)
2,67	3,2
4	2
4,33	4
4,67	3,4
5	3,2
5	3,6
5	5,2
5	5,2
5	4,6
5,33	2,8
5,33	3
5,67	5,4
5,67	4,8
5,67	3,8
5,67	3,6
5,67	3,8
6	4,6
6	4,4
7	4,6

Logro (Y)

Estatus (X)

$$\bar{Y} = 5,19 \quad \bar{X} = 3,96$$

Correlación

- La forma más simple de ver si dos variables están asociadas, es ver si presentan variación conjunta, es decir **covarian**. Eso nos remite primero al concepto de **varianza**.
- La varianza, como medida de dispersión, es una representación de cuánto varía un set de datos respecto de su promedio.

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum (x_i - \bar{x}) * (x_i - \bar{x})}{n}$$

- Por otro lado, en sentido de la variación conjunta de dos variables, se espera que cuando una variable se desvía de su promedio la otra se desvíe de su promedio de una forma similar (Field y Miles, 2014).

Correlación

Por ejemplo, una forma de representar esto puede ser la siguiente:

.

Correlación

Otra forma de visualizar la variación conjunta es generando un gráfico de puntos (scatterplot). Por ejemplo, si usamos los datos del ejemplo mencionado, se observa una tendencia.

Correlación

Varianza y covarianza

- Varianza

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum (x_i - \bar{x}) * (x_i - \bar{x})}{n}$$

- Covarianza

$$\text{Cov}(x, y) = \frac{\sum (x_i - \bar{x}) * (y_i - \bar{y})}{n-1}$$

- ¿Qué tienen en común las formulas de σ^2 y cov?

Suma de productos de desviación.

Varianza y covarianza

Estatus(X)	Logro(Y)	$(X - \bar{X})$	$(Y - \bar{Y})$	$(X - \bar{X})^2$	$(Y - \bar{Y})^2$	$(X - \bar{X}) * (Y - \bar{Y})$
2,67	3,2	-2,52	-0,76	6,35	0,58	1,92
4	2	-1,19	-1,96	1,42	3,84	2,33
4,33	4	-0,86	0,04	0,74	0,00	-0,03
4,67	3,4	-0,52	-0,56	0,27	0,31	0,29
5	3,2	-0,19	-0,76	0,04	0,58	0,14
5	3,6	-0,19	-0,36	0,04	0,13	0,07
5	5,2	-0,19	1,24	0,04	1,54	-0,24
5	5,2	-0,19	1,24	0,04	1,54	-0,24
5	4,6	-0,19	0,64	0,04	0,41	-0,12
5,33	2,8	0,14	-1,16	0,02	1,35	-0,16
5,33	3	0,14	-0,96	0,02	0,92	-0,13
5,67	5,4	0,48	1,44	0,23	2,07	0,69
5,67	4,8	0,48	0,84	0,23	0,71	0,40
5,67	3,8	0,48	-0,16	0,23	0,03	-0,08
5,67	3,6	0,48	-0,36	0,23	0,13	-0,17
5,67	3,8	0,48	-0,16	0,23	0,03	-0,08
6	4,6	0,81	0,64	0,66	0,41	0,52
6	4,4	0,81	0,44	0,66	0,19	0,36
7	4,6	1,81	0,64	3,28	0,41	1,16
$\bar{X} = 5,19$	$\bar{Y} = 3,96$			$\Sigma = 14,7$	$\Sigma = 15,17$	$\Sigma(x,y) = 6,63$

Estatus(X)	Logro(Y)	(X - $\bar{X}$)	(Y - $\bar{Y}$)	(X - $\bar{X}$) ²	(Y - $\bar{Y}$) ²	(X - $\bar{X}$) * (Y - $\bar{Y}$)
------------	----------	------------------	------------------	-------------------------------	-------------------------------	-------------------------------------

$\sigma^2 = 0,82$

$\sigma^2 = 0,84$

$cov(x,y) =$

Covarianza

Estatus(X)	Logro(Y)	(X- $\bar{X}$)	(Y- $\bar{Y}$)	(X- $\bar{X}$) ²	(Y- $\bar{Y}$) ²	(X- $\bar{X}$)*(Y- $\bar{Y}$) \
2,67	3,2	-2,52	-0,76	6,35	0,58	1,92
4	2	-1,19	-1,96	1,42	3,84	2,33
4,33	4	-0,86	0,04	0,74	0,00	-0,03
4,67	3,4	-0,52	-0,56	0,27	0,31	0,29
5	3,2	-0,19	-0,76	0,04	0,58	0,14
5	3,6	-0,19	-0,36	0,04	0,13	0,07
5	5,2	-0,19	1,24	0,04	1,54	-0,24
5	5,2	-0,19	1,24	0,04	1,54	-0,24
5	4,6	-0,19	0,64	0,04	0,41	-0,12
5,33	2,8	0,14	-1,16	0,02	1,35	-0,16
5,33	3	0,14	-0,96	0,02	0,92	-0,13
5,67	5,4	0,48	1,44	0,23	2,07	0,69
5,67	4,8	0,48	0,84	0,23	0,71	0,40
5,67	3,8	0,48	-0,16	0,23	0,03	-0,08
5,67	3,6	0,48	-0,36	0,23	0,13	-0,17
5,67	3,8	0,48	-0,16	0,23	0,03	-0,08
6	4,6	0,81	0,64	0,66	0,41	0,52
6	4,4	0,81	0,44	0,66	0,19	0,36
7	4,6	1,81	0,64	3,28	0,41	1,16
$\bar{X}=5,19$	$\bar{Y}=3,96$	0	0	$\Sigma = 14,7$	$\Sigma = 15,17$	$\Sigma(x,y) = 6,63$

Estatus(X)	Logro(Y)	(X- $\bar{X}$)	(Y- $\bar{Y}$)	(X- $\bar{X}$) ²	(Y- $\bar{Y}$) ²	(X- $\bar{X}$)*(Y- $\bar{Y}$) \
				$\sigma^2 = 0,82$	$\sigma^2 = 0,84$	$cov(x,y) = 0,37$

Covarianza

- Una primera medida de asociación a considerar es **la suma de productos de desviación**

$$\sum (x_i - \bar{x}) * (y_i - \bar{y})$$

$$(x_i - \bar{x}) * (y_i - \bar{y}) = (-2,52) * (-0,76) = 1,92$$

- Una segunda medida de asociación a considerar es **la covarianza**

$$\text{Cov}(x, y) = \frac{\sum (x_i - \bar{x}) * (y_i - \bar{y})}{n-1}$$

$$\text{Cov}(x, y) = \frac{6,63}{18} = 0,37$$

- ¿Qué nos indica?

Covarianza

Intuitivamente podemos interpretar este indicador según el sentido de la variación conjunta ($\sum(x, y) = 6,63$):

$$- * - = +$$

$$+ * + = +$$

$$- * + = -$$

$$+ * - = -$$

Correlación de Pearson

Correlación de Pearson (producto-momento de Pearson).

Estatus(X)	Logro(Y)	$(X - \bar{X})$	$(Y - \bar{Y})$	$(X - \bar{X})^2$	$(Y - \bar{Y})^2$	$(X - \bar{X}) * (Y - \bar{Y})$
2,67	3,2	-2,52	-0,76	6,35	0,58	1,92
4	2	-1,19	-1,96	1,42	3,84	2,33
4,33	4	-0,86	0,04	0,74	0,00	-0,03
4,67	3,4	-0,52	-0,56	0,27	0,31	0,29
5	3,2	-0,19	-0,76	0,04	0,58	0,14
5	3,6	-0,19	-0,36	0,04	0,13	0,07
5	5,2	-0,19	1,24	0,04	1,54	-0,24
5	5,2	-0,19	1,24	0,04	1,54	-0,24
5	4,6	-0,19	0,64	0,04	0,41	-0,12
5,33	2,8	0,14	-1,16	0,02	1,35	-0,16
5,33	3	0,14	-0,96	0,02	0,92	-0,13
5,67	5,4	0,48	1,44	0,23	2,07	0,69
5,67	4,8	0,48	0,84	0,23	0,71	0,40
5,67	3,8	0,48	-0,16	0,23	0,03	-0,08
5,67	3,6	0,48	-0,36	0,23	0,13	-0,17
5,67	3,8	0,48	-0,16	0,23	0,03	-0,08
6	4,6	0,81	0,64	0,66	0,41	0,52
6	4,4	0,81	0,44	0,66	0,19	0,36
7	4,6	1,81	0,64	3,28	0,41	1,16
$\bar{X} = 5,19$	$\bar{Y} = 3,96$	0	0	$\Sigma = 14,7$	$\Sigma = 15,17$	$\Sigma(x,y) = 6,63$

Estatus(X)	Logro(Y)	$(X - \bar{X})$	$(Y - \bar{Y})$	$(X - \bar{X})^2$	$(Y - \bar{Y})^2$	$(X - \bar{X}) * (Y - \bar{Y})$
				$\sigma^2 = 0,82$	$\sigma^2 = 0,84$	$\text{cov}(x, y) = 0,37$
				$\sigma = 0,90$	$\sigma = 0,92$	$r(x, y) = 0,44$

Correlación

Una tercera medida de asociación a considerar es **la correlación de pearson**

$$r(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

$$r(x, y) = \frac{0,37}{\sqrt{0,82*0,84}} = 0,44$$

- Puede ser considerada como una estadarización de la covarianza.

Otro camino para el mismo resultado.

$$r(x, y) = \frac{\frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}}{\sqrt{\frac{\sum(x_i - \bar{x})^2}{n-1}} * \sqrt{\frac{\sum(y_i - \bar{y})^2}{n-1}}}$$

El factor común n-1 se remueve

$$r(x, y) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2} * \sqrt{\sum(y_i - \bar{y})^2}}$$

$$r(x, y) = \frac{6,63}{\sqrt{14,7 * 15,17}} = 0,44$$

Correlación

Cada una de estas medidas aporta información sobre la asociación entre dos variables:

- ¿Dirección de la asociación?
- ¿Magnitud o grado de la asociación?

Para el caso de la correlación de Person:

- Grado de asociación, independiente de la escala de las variables.
- Expresada en escala estandarizada (-1 a 1)
- Captura la relación líneal entre variables
- ¿Significancia estadística?

Algunas consideraciones: Diferentes datos, misma correlación

```
1 x=c(10,8,13,9,11,14,6,4,12,7,5)
2 x2=c(8,8,8,8,8,8,8,19,8,8,8)
3 y1=c(8.04,6.95,7.58,8.81,8.33,9.96,7.24,4.26,10.84,4.82,5.68)
4 y2=c(9.14,8.14,8.74,8.77,9.26,8.10,6.13,3.10,9.13,7.26,4.74)
5 y3=c(7.46,6.77,12.74,7.11,7.81,8.84,6.08,5.39,8.15,6.42,5.73)
6 y4=c(6.58,5.76,7.71,8.84,8.47,7.04,5.25,12.5,5.56,7.91,6.89)
7 ej1=data.frame(x,x2,y1, y2, y3, y4)
8 library(Hmisc)
9 library(kableExtra)
10 kable(ej1)
```

x	x2	y1	y2	y3	y4
10	8	8.04	9.14	7.46	6.58
8	8	6.95	8.14	6.77	5.76
13	8	7.58	8.74	12.74	7.71
9	8	8.81	8.77	7.11	8.84
11	8	8.33	9.26	7.81	8.47
14	8	9.96	8.10	8.84	7.04
6	8	7.24	6.13	6.08	5.25
4	19	4.26	3.10	5.39	12.50
12	8	10.84	9.13	8.15	5.56
7	8	4.82	7.26	6.42	7.91
5	8	5.68	4.74	5.73	6.89

Algunas consideraciones: Diferentes datos, misma correlación

	x	x2	y1	y2	y3	y4
x	1.0000000	-0.5000000	0.8164205	0.8162365	0.8162867	-0.3140467
x2	-0.5000000	1.0000000	-0.5290927	-0.7184365	-0.3446610	0.8165214
y1	0.8164205	-0.5290927	1.0000000	0.7500054	0.4687167	-0.4891162
y2	0.8162365	-0.7184365	0.7500054	1.0000000	0.5879193	-0.4780949
y3	0.8162867	-0.3446610	0.4687167	0.5879193	1.0000000	-0.1554718
y4	-0.3140467	0.8165214	-0.4891162	-0.4780949	-0.1554718	1.0000000

Algunas consideraciones: Diferentes datos, misma correlación

[1] 0.8164205

Algunas consideraciones: Diferentes datos, misma correlación

Algunas consideraciones: Diferentes datos, misma correlación

Algunas consideraciones: Diferentes datos, misma correlación

Algunas consideraciones: Diferentes datos, misma correlación

La importancia la exploración gráfica

```
# A tibble: 13 × 6
```

	dataset	mean_x	mean_y	std_dev_x	std_dev_y	corr_x_y
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	away	54.3	47.8	16.8	26.9	-0.0641
2	bullseye	54.3	47.8	16.8	26.9	-0.0686
3	circle	54.3	47.8	16.8	26.9	-0.0683
4	dino	54.3	47.8	16.8	26.9	-0.0645
5	dots	54.3	47.8	16.8	26.9	-0.0603
6	h_lines	54.3	47.8	16.8	26.9	-0.0617
7	high_lines	54.3	47.8	16.8	26.9	-0.0685
8	slant_down	54.3	47.8	16.8	26.9	-0.0690
9	slant_up	54.3	47.8	16.8	26.9	-0.0686
10	star	54.3	47.8	16.8	26.9	-0.0630
11	v_lines	54.3	47.8	16.8	26.9	-0.0694
12	wide_lines	54.3	47.8	16.8	26.9	-0.0666
13	x_shape	54.3	47.8	16.8	26.9	-0.0656

La importancia la exploración gráfica

Correlación

El índice de correlación puede ser entendido como un indicador de varianza compartida:

- r^2_{xy} Proporción de la varianza que comparten dos variables
-

Significancia de una correlación.

- Una aproximación, puede ser calcular el valor t asociado al índice, con n-2 grados de libertad.

- $t_r = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$

Donde el $r^2 = 0.20$ es la varianza compartida.

- $t_r = \frac{0.44\sqrt{19-2}}{\sqrt{1-0.20}} = 2.1$

- La probabilidad asociada a $t_r = 2.1$; gl = 17; p = 0.059
- ¿Qué pasa si modificamos el N?

Significancia de una correlación.

- Una aproximación, puede ser calcular el valor t asociado al índice, con n-2 grados de libertad.

- $t_r = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$

Donde el $r^2 = 0.20$ es la varianza compartida.

- $t_r = \frac{0.44\sqrt{30-2}}{\sqrt{1-0.20}} = 2.1$
- La probabilidad asociada a $t_r = 2.60$; gl = 28; $p = 0.014$
- ¿Qué pasa si modificamos el N?

En resumen:

- La covarianza es una medida simple de asociación entre dos variables
- El resultado de la estandarización de la covarianza es el coeficiente de correlación de Pearson.
- Este coeficiente varía entre -1 a +1

En resumen:

- Un coeficiente de 1 indica una asociación lineal positiva perfecta, un coeficiente de -1 indica una asociación lineal negativa perfecta y un coeficiente de 0 indica que NO hay una relación lineal.
- Un criterio para evaluar el tamaño de la correlación propuesto por Cohen es: ± 0.1 representa una asociación pequeña, ± 0.3 representa una asociación mediana y ± 0.5 representa una asociación grande.

Sin embargo,

- Una correlación indica sólo asociación entre variables. No es posible identificar que variable predice la otra (Fields, 2014).
- Además, se presenta el problema de la variable omitida.

Modelo de Regresión lineal

Regresión lineal

- Se define como: $Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_K X_{iK} + \epsilon_i$

donde Y es la variable dependiente, las $X_1 \dots X_K$ son las variables independientes, y ϵ es el componente aleatorio.

- El parámetro β_0 es el intercepto, mientras que β_K es el coeficiente de regresión parcial asociado a la variable X_K .

Modelo de Regresión lineal

- Esto es, β_k mide cuanto cambia, en promedio, Y ante el cambio de una unidad de X_k , manteniendo constantes todos los valores de las demás variables independientes.
- Esta interpretación del “efecto marginal” se vuelve más compleja cuando hay interacciones.
- La estimación de los parámetros β_k y σ^2 se realiza vía MCO o ML (con el supuesto paramétrico de normalidad).

Modelo de regresión Lineal

- Si tomamos el valor esperado de Y tenemos:

$$\begin{aligned} E(Y_i) &= E(\beta_0 + \beta_1 X_{i1} + \dots + \beta_K X_{iK} + \epsilon_i) \\ &= \beta_0 + \beta_1 X_{i1} + \dots + \beta_K X_{iK} \end{aligned}$$

- Es decir, el modelo de regresión nos entrega el valor esperado de Y condicionada a los valores dados de las X_k .
- Como señala Gelman y Hill, la regresión lineal es un método que resume cómo los valores esperados de una variable numerica varían entre sub-grupos de una población definidas por medio de funciones lineales de los predictores.

Supuestos de regresión Lineal

Linealidad:

- La variable Y es esta asociada linealmente a las variables X_k por medio de los parámetros β_k .
- Se permiten relaciones no lineales por medio de transformaciones matemáticas de las variables.

Supuestos de regresión Lineal

Colinealidad:

- Las variables dentro de la matriz $\mathbf{X}$ son linealmente independientes.
- Técnicamente, ninguna X_k es una combinación lineal de las otras X_k .
- Esto no implica que las distintas X_k no puedan estar correlacionadas o asociadas en forma no-lineal.

Supuestos de regresión Lineal

El valor esperado de los residuos, dado las X_k , es zero.

Formalmente: $E(\epsilon_i | X_k) = 0$

- Factores explícitamente excluidos del modelo no afectan de forma sistemática el valor medio de Y .
- Intuitivamente, los valores ϵ_i positivos se cancelan con los valores ϵ_i negativos.

Supuestos de regresión Lineal

Homocedasticidad:

- Dado los valores de X_k , los residuos tienen varianza constante. Esto es:

$$\text{Var}(\epsilon_i | X_k) = \sigma^2$$

- En otras palabras, las varianzas condicionales de cada ϵ_i son idénticas.

Supuestos de regresión Lineal

Homocedasticidad y Heterocedasticidad

- El supuesto de homocedasticidad implica que todas las observaciones deben tener igual ponderación sobre los datos.
- Cuando esto no aplica la solución es usar ... mínimos cuadrados ordinarios ponderados.

Supuestos de regresión Lineal

Auto-correlación de los residuos

- Se asume que los residuos son independientes entre sí. Dada dos observaciones i y j ,

$$\begin{aligned}\text{cov}(\epsilon_i, \epsilon_j | X_{ik}, X_{jk}) &= E[(\epsilon_i - E(\epsilon_i) | X_{ij}) (\epsilon_j - E(\epsilon_j) | X_{ij})] \\ &= E(\epsilon_i | X_{ij}) (\epsilon_j | X_{ij}) \\ &= 0\end{aligned}$$

- Dada las X_k , las desviaciones de los valores de Y de su valor medio no muestran patrones sistemáticos.
- Este supuesto se rompe típicamente con datos de series temporales.

Supuestos de regresión Lineal

El modelo esta correctamente especificado.

- Caso contrario pueden haber sesgos por variables omitidas o por sesgos por especificación errada.

Supuestos de regresión Lineal

Los residuos se distribuyen en forma normal. Esto es, $\epsilon_i \sim N(0, \sigma^2)$

- Este supuesto asegura que la distribución muestral de los coeficientes β_k sea normal, y por ende, permite realizar inferencia estadística.
- ¿Por qué? Cualquier función lineal de una variable con distribución normal también se distribuye en forma normal.
- Hay algunos autores que reclaman que este supuesto no es necesario ya que el *teorema central del límite* asegura la distribución muestral normal de los β_k .

Supuestos de regresión Lineal

Zero covarianza entre ϵ y las variables X_{ik} , o $E(\epsilon_i X_{ik}) = 0$.

Formalmente:

$$\begin{aligned}\text{Cov}(\epsilon_i, X_{ik}) &= E[\epsilon_i - E(\epsilon_i)][X_{ik} - E(X_{ik})], \text{ dado que } E(\epsilon_i) = 0 \\ &= E[\epsilon_i (X_{ik} - E(X_{ik}))], \text{ dado que } X \text{ es fija: } = E(\epsilon_i X_{ik}) \\ &= 0\end{aligned}$$

- Este supuesto también es referido como exogeneidad de las X_k .
- Es crítico en la medida en que se quiera interpretar el β como un efecto causal. Si no es el caso, no es tan relevante.

Supuestos de regresión Lineal

- Hay otros supuestos más, pero son de menor importancia o demasiado obvios que muchas veces son omitidos.
- Los valores de las variables independientes deben variar.
- El numero de observaciones tiene que ser mayor al número de parámetros que se buscan estimar.

Estimación del Modelo Lineal

- Los parámetros del modelo de regresión lineal pueden ser estimados por medio de:
 - Minimización de Cuadrados Ordinarios (MCO).
 - Máxima Verosimilitud (MLE).

Bondad de Ajuste

- Por lejos la medición más empleada para evaluar la bondad de ajuste de un modelo lineal es el R cuadrado:

$$\begin{aligned} R^2 &= \frac{(\hat{Y}_i - \bar{Y})^2}{(Y_i - \bar{Y})^2} \\ &= \frac{SC_{\text{explicado}}}{SC_{\text{total}}} = 1 - \frac{SC_{\text{residual}}}{SC_{\text{total}}} = 1 - \frac{\sum \epsilon_i^2}{\sum (Y_i - \bar{Y})^2} \end{aligned}$$

- Indica el porcentaje de variación en Y que es explicado por el conjunto de variables independientes.

Bondad de Ajuste

- Un problema del R^2 es que es una función no decreciente del número de variables explicativas incluidas en el modelo.
- $\sum \epsilon_i^2$ tiende a bajar levemente aún en la presencia de variables irrelevantes.
- Entonces para comparar modelos con diferente número de variables explicativas el R_A^2 (R cuadrado ajustado) penaliza por la complejidad del modelo:

$$R_A^2 = 1 - \frac{\sum \epsilon_i^2 / (n - k)}{\sum (Y_i - \bar{Y})^2 / (n - 1)}$$

- En razón de la penalización siempre $R_A^2 < R^2$.

De modo un poco más simple

Test de Hipótesis

- A continuación veremos variados test de hipótesis con propósitos diferentes:
 - Prueba de hipótesis acerca de un coeficiente de regresión parcial individual.
 - Prueba de la significancia global del modelo de regresión múltiple.
 - Prueba de hipótesis de restricción de parámetros.

Prueba de hipótesis de un coeficiente parcial individual

- Gracias al supuesto de $\epsilon \sim N(0, \sigma^2)$ podemos asumir que $\hat{\beta}_k \sim N(\beta_k, V(\beta_k))$
- Por defecto las hipótesis son: $H_0 : \beta_k = 0$ $H_A : \beta_k \neq 0$

Prueba de hipótesis de un coeficiente parcial individual

- Los pasos a seguir son:
 - Computar estadístico $t = \beta_k / \sqrt{\overline{V\beta_k}}$.
 - Definir nivel aceptable de error: $\alpha = 0.05$ y valor crítico asociado $t_{\alpha/2}$.
 - Contrastar valor t con valor crítico usando una curva normal o t de student (para muestras pequeñas) al nivel determinado de α .
 - Si valor $t > t_{\alpha/2}$ no se acepta (o se rechaza) la H_0 .

Prueba de hipótesis de un coeficiente parcial individual

- Alternativamente, se puede calcular directamente el *valor p* asociado al estadístico t y ver si es mayor o menor a nivel aceptable de error.
- **Interpretación:** Un valor $p = 0.02$ indica que asumiendo que $H_0 : \beta_k = 0$ es verdadera, la probabilidad de observar un valor igual o mayor al estadístico t por simple azar es de un 2%.

Intervalos de Confianza

- Como alternativa a una prueba de hipótesis se pueden calcular los intervalos de confianza de un $\hat{\beta}_k$. Equivale a:

$$\hat{\beta}_k - t_{\alpha/2} \sqrt{V(\hat{\beta}_k)} \leq \beta_k \leq \hat{\beta}_k + t_{\alpha/2} \sqrt{V(\hat{\beta}_k)}$$

- ¿Qué significa que los intervalos incluyan el valor 0?
- **Interpretación:** Si obtuviéramos infinitas muestras equivalentes esperamos que el β_k (verdadero valor poblacional) este incluido en los intervalos en un 95% de las veces.

Prueba Significancia Global del Modelo

- Esta prueba es comúnmente realizada, y reportada por defecto en muchos programas estadísticos.
- Consiste en evaluar si el efecto conjunto de todos los coeficientes incluidos en un modelo son significativos.
- Formalmente corresponde a: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$
- Para esto empleamos la distribución F
- Una variable aleatoria que sea una razón entre dos variables aleatorias con distribución χ^2 (con grados de libertad d_1 y d_2), sigue una distribución F con grados de libertad d_1 y d_2 .

Prueba Significancia Global del Modelo

Los pasos a seguir son:

- Computar estadístico

$$F = \frac{\sum(\hat{Y}_i - \bar{Y})^2 / gl_1}{\sum(Y_i - \hat{Y}_i)^2 / gl_2} = \frac{SC_{\text{explicados}} / (k-1)}{SC_{\text{residuales}} / (n-k)}$$

- Si $F > F_{\alpha}(k-1, n-k)$ se rechaza la H_0 .
- Alternativamente, se puede calcular directamente el *valor p* asociado al estadístico F y ver si es mayor o menor a nivel aceptable de error.

Test F

- Es más fácil comprender el estadístico F, y su gran potencial, si se considera su estrecha relación con el R^2 .

$$\begin{aligned} F &= \frac{SC_{\text{explicados}}/(k-1)}{SC_{\text{residuales}}/(n-k)} \\ &= \frac{n-k}{k-1} \frac{SC_{\text{explicados}}}{SC_{\text{residuales}}} \\ &= \frac{n-k}{k-1} \frac{SC_{\text{explicados}}/SC_{\text{totales}}}{SC_{\text{residuales}}/SC_{\text{totales}}} \\ &= \frac{n-k}{k-1} \frac{SC_{\text{explicados}}/SC_{\text{totales}}}{(1-SC_{\text{explicados}}/SC_{\text{totales}})} \\ &= \frac{n-k}{k-1} \frac{R^2}{1-R^2} \\ &= \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \end{aligned}$$

Test F

- Dada esta conexión entre el estadístico F y el R^2 , la hipótesis nula $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$ equivale a que?
- $H_0 : R^2 = ??$

Restricción de parámetros y Test F

- Los casos anteriores $H_0 : \beta_k = 0$ o $H_0 : R^2 = 0$ son casos particulares del test F.
- Por medio de este test se pueden establecer todo tipo de pruebas que impliquen restricciones específicas al modelo.
- Típicamente es muy útil saber si el efecto colectivo de un conjunto de variables es significativo o no.
 - Por ejemplo, en un modelo con 9 predictores uno quisiera evaluar: $H_0 : \beta_3 = \beta_4 = \beta_5 = 0$

Test F General

La estrategia más general del test F es la siguiente:

- Definir dos modelos: modelo completo y el modelo restringido (o constreñido).
 - El modelo restringido corresponde al que se le aplican las restricciones especificadas en las hipótesis.

Test F General

- Se estima el modelo completo y restringido (o constreñido), y extraen los R^2 .
- Modelo completo: R_C^2 con $n - k$ grados de libertad.
- Modelo restringido: R_R^2 con m grados de libertad, donde m es el número de parámetros restringidos.
- Se calcula $F = \frac{(R_C^2 - R_R^2)/(m)}{(1 - R_C^2)/(n - k)}$
- Regla: Si $F > F_{\alpha}(m, [n - k])$ se rechaza H_0 .

Ejemplo: Lectura de datos

```
1 corr <- read.table("./correlacion.txt", header=TRUE)
2 library(stargazer)
3
4 print=stargazer(corr, title="Descriptivos", type="html", single.row=TRUE, align=TRUE)
5
6 corma <- cor(corr)
7 print=stargazer(corma, title="Matriz de correlaciones", type="html")
```

Ejemplo: Descriptivos

Statistic	N	Mean	St. Dev.	Min	Max
Revisar	103	19.854	18.159	0	98
Rendimiento	103	56.573	25.941	2	100
Ansiedad	103	74.344	17.182	0.056	97.582

Ejemplo: Correlaciones

	Revisar	Rendimiento	Ansiedad
Revisar	1	0.397	-0.709
Rendimiento	0.397	1	-0.441
Ansiedad	-0.709	-0.441	1

Ejemplo: Estimación

```
1 corr <- read.table("../input/correlacion.txt", header=TRUE)
2 #corr
3 #install.packages("QuantPsyc")
4 #install.packages("stargazer")
5 library(QuantPsyc)
6 reg1 <- lm(Rendimiento ~ + Ansiedad, data = corr)
7 reg2 <- lm(Rendimiento ~ + Ansiedad + Revisar, data = corr)
```

Ejemplo: Resultado de la estimación

Dependent variable:

Ansiedad	-0.666 ^{***} (0.135)	-0.485 ^{**} (0.191)
Revisar		0.241 (0.180)
Constant	106.071 ^{***} (10.285)	87.833 ^{***} (17.047)
Observations	103	103
R ²	0.194	0.209
Adjusted R ²	0.186	0.193
F Statistic	24.384 ^{***} (df = 1; 101)	13.184 ^{***} (df = 2; 100)

Note: *p<0.1; **p<0.05; ***p<0.01

Ejemplo: Crear variables auxiliares

```
1 error=resid(reg1)# Crea variable residuos
2 yhat=fitted(reg1) #Crea variable valores predichos
3
4 error2=resid(reg2)# Crea variable residuos
5 yhat2=fitted(reg2) #Crea variable valores predichos
```

Significancia de los coeficientes

Calculo de la significancia de β_1

- La significación se puede calcular utilizando el error estándar β , que se obtiene a partir de la varianza de los residuos.
- $$\frac{\sum (y_i - \hat{y}_i)^2}{N-k-1} = \frac{SS_{\text{res}}}{N-k-1}$$
- $$S_b = \sqrt{\frac{\text{Var}(xy)}{\sum (x - \bar{x})^2}}$$
- $$t = \frac{\hat{\beta}}{S_b} = -0.666/0.135 = -4.933$$

Significancia de los coeficientes

- La significancia se evalúa obteniendo el p_{value} asociado a un t_{N-1} .

```
1 2*pt(-abs(-4.933),df=103-1-1)
```

```
[1] 3.193406e-06
```

Significancia de los coeficientes

Intervalo de confianza $\beta_1 \pm t_{(\alpha/2, df)} * S_{\beta_a}$

- Requiere buscar valor t asociado a un nivel de confianza (p.e. 0.05 ó 95 por ciento de confianza) para los grados de libertad respectivos, en tabla de valores $t(0.025, 101) = -1.984$
- $-0.666 \pm (-1.98 * 0.135)$
- $-0.93 < -0.666 < -0.40$

Significancia de los coeficientes

- Interpretación: Si obtuviéramos infinitas muestras equivalentes esperamos que el $\beta_1 = -0.666$ (verdadero en la población) es incluido en los intervalos en un 95 por ciento de las veces.
- ¿Qué significa que los intervalos incluyan el valor 0?

Ejemplo

Interprete los resultados del modelo:

Dependent variable:

Ansiedad	-0.666 ^{***} (0.135)	-0.485 ^{**} (0.191)
Revisar		0.241 (0.180)
Constant	106.071 ^{***} (10.285)	87.833 ^{***} (17.047)
Observations	103	103
R ²	0.194	0.209
Adjusted R ²	0.186	0.193
F Statistic	24.384 ^{***} (df = 1; 101)	13.184 ^{***} (df = 2; 100)

Note: * p<0.1; ** p<0.05; *** p<0.01

Una pequeña extensión: uso de dummy (categóricas)

Para capturar relaciones no lineales o evaluar el efecto de variable dicotómicas, es posible usar dummies en un modelo de regresión:

- Estas variables no indican cierta posible magnitud o cantidad de una variable, sino básicamente la presencia o ausencia de algún atributo o característica.
- Por definición las variables dummy son binarias, es decir, pueden tomar dos posibles valores.

Coeficientes estandarizados

Estandarización de coeficientes:

$$\beta_1 = \beta \frac{s_x}{s_y}$$

- Permite comparar coeficientes en términos de la predicción relativa independientemente de las escalas originales (si la escala es la misma, se pueden comparar directamente).
- Equivale a la regresión realizada con las variables estandarizadas.
- Los coeficientes estandarizados se interpretan como el número de desviaciones estándar de Y según una desviación estándar de X
- Sin embargo, esto tiene algunas limitaciones:
 - Los coeficientes tienen un significado menos intuitivo
 - No aplicable a variables categóricas (dummy). La estandarización es diferente para cada grupo.

Coeficientes estandarizados

Estandarización de coeficientes:

$$\beta_1 = \beta \frac{s_x}{s_y}$$

<i>Dependent variable:</i>	
Ansiedad	-0.485** (0.191)
Revisar	0.241 (0.180)
Constant	87.833*** (17.047)
Observations	103

Note: * p<0.1; ** p<0.05; *** p<0.01

Ansiedad Revisar -0.3211 0.1689

Descomposición de la varianza

La varianza de Y_i puede descomponerse entonces como:

$$\sum (y_i - \bar{y})^2 = \sum (\bar{y} - \hat{y}_i)^2 + \sum (y_i - \hat{y}_i)^2$$

$$SS_{\text{total}} = SS_{\text{reg}} + SS_{\text{error}}$$

- Los grados de libertad consideran el número de parámetros que se fijan: $(n - 1)$

```
1 var(corr$Rendimiento) #Varianza Total (SSC Total)
2 var(yhat) #Varianza valores predihos (SSC reg)
3 var(error) #Varianza del error (SSC error)
```

[1] 672.9138 Varianza total [1] 130.865 Varianza de valores predichos [1] 542.0487 Varianza del error

$$Var_{\text{total}} = Var_{\text{reg}} + Var_{\text{error}} = 130.865 + 542.0487 = 672.9138$$

Bondad de ajuste

<i>Dependent variable:</i>	
Ansiedad	-0.666 ^{***} (0.135)
Constant	106.071 ^{***} (10.285)
Observations	103
R ²	0.194
Adjusted R ²	0.186
F Statistic	24.384 ^{***} (df = 1; 101)
Note:	* p<0.1; ** p<0.05; *** p<0.01

Bondad de ajuste

El R^2 es utilizado ampliamente como un indicador de Bondad de ajuste. Este indica el porcentaje (proporción) de variación de Y explicada por el conjunto de variables independientes.

$$R^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}}$$

- Tiende a aumentar con el ingreso de variables (incluso ante variables irrelevantes)
- Para corregir por esto, usualmente se reporta el R^2 ajustado, que penaliza por la cantidad de predictores adicionales
- $\text{Adj. } R^2 = (R^2 - \frac{k}{n-1})(\frac{n-1}{n-k-1})$

Bondad de ajuste: R^2

[1] 672.9138 Varianza total [1] 130.865 Varianza de valores predichos [1] 542.0487 Varianza del error
 R^2

$$R^2 = \frac{SS_{\text{reg}}}{SS_{\text{total}}}$$
$$R^2 = \frac{130.865}{672.9138} = 0.194$$

Bondad de ajuste: R^2 ajustado

R^2 ajustado

$$\text{Adj. } R^2 = (R^2 - \frac{k}{n-1})(\frac{n-1}{n-k-1})$$

$$\text{Adj. } R^2 = (0.194 - \frac{1}{102})(\frac{102}{101}) = 0.186$$

Test de significación del modelo

- Los software estadísticos reportan por defecto el test global del modelo
- Consiste en evaluar si el efecto del conjunto de todos los coeficientes incluidos en el modelo son significativos

$$F = \frac{SS_{\text{reg}}/df_1}{SS_{\text{error}}/df_2} = \frac{SS_{\text{reg}}/k}{SS_{\text{error}}/N-k-1}$$

- Se desprende de la formula como la relación entre la varianza explicada y la varianza error
- El estadístico sigue una distribución F con grados de libertad $df_1 = k$ y $df_2 = n - k - 1$, lo que permite hacer contraste de hipótesis.

Test de significación del modelo

Pasos para evaluar el modelo global:

- Computar el estadístico F $F = \frac{SS_{\text{reg}}/df_1}{SS_{\text{error}}/df_2} = \frac{SS_{\text{reg}}/k}{SS_{\text{error}}/N-k-1}$

si $F > F_{\alpha}(k, n - k)$, se rechaza H_0 .

- También, se puede observar el p-value asociado al estadístico F y ver si es mayor o menor que el nivel de error definido (0.05).

Test de significación del modelo

- Por medio de este test, se puede establecer todo tipo de pruebas que impliquen restricciones específicas al modelo.
- $F = \frac{SS_{\text{reg}}/df_1}{SS_{\text{error}}/df_2} = \frac{SS_{\text{reg}}/k}{SS_{\text{error}}/N-k-1}$
- si $F > F_{\alpha}(k, n - k - 1)$, se rechaza H_0 .

Test de significación del modelo

[1] 672.9138 Varianza total [1] 130.865 Varianza de valores predichos [1] 542.0487 Varianza del error

- $F = \frac{SS_{\text{reg}}/df_1}{SS_{\text{error}}/df_2} = \frac{SS_{\text{reg}}/k}{SS_{\text{error}}/N-k-1}$
- $F = \frac{130.865/1}{542.0487/101} = 24.384$

1 (130.865/1)/(542.0487/101)

[1] 24.38409

Test de significación del modelo

Dependent variable:

Rendimiento

	(1)	(2)
Ansiedad	-0.666 ^{***} (0.135)	-0.485 ^{**} (0.191)
Revisar		0.241 (0.180)
Constant	106.071 ^{***} (10.285)	87.833 ^{***} (17.047)
Observations	103	103
R ²	0.194	0.209
Adjusted R ²	0.186	0.193
F Statistic	24.384 ^{***} (df = 1; 101)	13.184 ^{***} (df = 2; 100)

Note: * p<0.1; ** p<0.05; *** p<0.01

Test de significación del modelo

- $F = \frac{SS_{\text{reg}}/df_1}{SS_{\text{error}}/df_2} = \frac{SS_{\text{reg}}/k}{SS_{\text{error}}/N-k-1}$
- $F = \frac{140.407/2}{532.5068/100} = 13.184$

```
1 (140.407/2)/(532.5068/100)
2
3 #((0.194-0.209)/1)/((1-0.209)/99)
```

```
[1] 13.18359
```

Comparación de modelos

- Por medio de este test se pueden establecer comparaciones que impliquen restricciones específicas a los modelos.
- Evaluar si un predictor específico mejora el modelo o hipótesis acerca de un predictor específico.
- Por ejemplo: $H_0 = \beta_1 = \beta_2 = 0$

Comparación de modelos

- La forma más general implica definir dos modelos: Modelo completo y modelo restringido.
- Se estiman los modelos definidos. El modelo completo con $F_{gl} = n - k - 1$ y el modelo restringido con $F_{gl} = (n - k - 1) - m$, siendo m el número de parámetros restringidos.

Comparación de modelos

```
1 anova(reg1, reg2)
```

Analysis of Variance Table

- Model 1: Rendimiento ~ Ansiedad
- Model 2: Rendimiento ~ Ansiedad + Revisar

	df	SS	Delta df	Delta SC	F	P value
1	101	55289				
2	100	54316	1	973.28	1.79	0.1837

Una pequeña extensión: uso de dummy (categóricas)

- Como práctica generalizada se emplea el 1 para indicar la presencia de cierto atributo, y 0 su ausencia
- Ejemplos: hombre/mujer, casado/no casado, religioso/no religioso, ocupado/desempleado, etc.
- En estas situaciones se pueden crear $m - 1$ variables donde m es el numero de categorías que puede tomar la variable en cuestión, e introducirlas en el modelo de regresión.

Ejemplo con variables categóricas

<i>Dependent variable:</i>		
Educación (como continua)	34.041 ^{***}	(0.966)
hiscedb< ISCED LEVEL 1>	-6.389	(12.680)
hiscedb< ISCED LEVEL 2>	5.936	(10.023)
hiscedb< ISCED LEVEL 3>	39.380 ^{***}	(9.769)
hiscedb< ISCED LEVEL 4 OR 5B>	77.246 ^{***}	(9.989)
hiscedb< ISCED LEVEL 5A OR 6>	116.489 ^{***}	(9.894)
Constant	344.889 ^{***}	(4.379) 437.785 ^{***} (9.633)
Observations	5,126	5,126
<i>Note:</i> * p<0.1; ** p<0.05; *** p<0.01		